UNIVERSIDAD NACIONAL DE COLOMBIA

Dinámica estocástica y comportamiento gregario en el modelado de retornos de activos financieros

Juan Diego Rueda Mantilla

Universidad Nacional de Colombia
Facultad de Ciencias
Departamento de Física
Bogotá, Colombia
Julio 2025

Dinámica estocástica y comportamiento gregario en el modelado de retornos de activos financieros

Juan Diego Rueda Mantilla

Director de trabajo de grado:
Carlos José Quimbay Herrera

Universidad Nacional de Colombia
Facultad de Ciencias
Departamento de Física
Bogotá, Colombia
Julio 2025

Agradecimientos

Este trabajo no es más que el producto de la influencia de personas admirables a quienes me permito agradecerles:
A Dios, por darme la mano y guiarme en este camino.
Al profesor Carlos José Quimbay Herrera, quien despertó en mí la curiosidad por la econofísica y me dirigió en este proceso de estudio.
A mis padres, Samuel y Adriana, por enseñarme con cariño y paciencia las lecciones más importantes de mi vida. Nunca me alcanzarán las palabras para agradecerles todo lo que han dado y hecho por mí.
A mis abuelos, Carlos e Isabel Cristina, quienes me han brindado un amor puro e incondicional en cada paso que he dado.
A mis amigos, por haber sido acompañantes y confidentes en los ajetreos diarios.
A Anita, mi hermana, por ser la más hermosa inspiración que me hace crecer cada día.

Resumen

Este trabajo tiene como objetivo principal estudiar el comportamiento estadístico de los retornos financieros mediante la implementación y el análisis de modelos que integran dinámicas microscópicas a través de una retroalimentación estocástica. Se consideran dos aproximaciones fundamentales, una basada en distribuciones gaussianas y otra en distribuciones q-gaussianas. Para desarrollar estas aproximaciones, se inicia con una descripción detallada del movimiento browniano geométrico, mostrando cómo este conduce de forma natural a un modelo gaussiano de retornos bajo los supuestos clásicos del mercado. Posteriormente, se introduce de manera formal la mecánica estadística no extensiva propuesta por Tsallis, desde sus fundamentos teóricos hasta sus implicaciones en la forma funcional de las distribuciones de probabilidad. Esto permite justificar rigurosamente el uso del modelo q-gaussiano como una generalización adecuada para sistemas complejos con correlaciones de largo alcance. Adicionalmente, se desarrolla en detalle el modelo de Kirman, el cual representa un sistema con comportamiento gregario y transiciones estocásticas entre tres tipos de agentes. Este modelo se formula de manera continua mediante una ecuación de Fokker–Planck, que luego se transforma en una ecuación estocástica tipo Langevin. Esta formulación permite hacer un vínculo, propuesto por Kononovicius y Gontis, entre el modelo de agentes y los modelos de retornos mediante una definición funcional de la volatilidad que depende del estado dinámico del sistema. A partir de esta integración se diseñan dos esquemas de simulación que emplean ruido gaussiano y q-gaussiano respectivamente, ambos modulados por la volatilidad generada por la dinámica de los agentes. Los resultados simulados se comparan con datos empíricos de alta frecuencia correspondientes a acciones de las bolsas de Nueva York, Varsovia y Vilnius, así como con datos diarios del precio del barril de petróleo Brent y de la tasa de cambio entre el peso colombiano y el dólar estadounidense. Se observa que el modelo q-gaussiano reproduce de manera precisa las colas pesadas que caracterizan a los retornos accionariales, mientras que el modelo gaussiano logra un mejor ajuste en activos como el petróleo y el dólar, donde las distribuciones presentan colas más delgadas. Además, se evidencia una importante invariancia a escala en las simulaciones, más precisamente en el caso gaussiano, lo que sugiere una estructura robusta en las distribuciones generadas por el modelo. Un hallazgo central del estudio es la existencia de un límite interno para la validez de la simulación, resultado de la desaparición progresiva de los agentes fundamentalistas en escenarios de largo plazo. Esta dinámica conduce a una divergencia en la volatilidad que corresponde a una propiedad emergente del propio modelo, la cual define de forma natural su dominio de aplicabilidad. En conjunto, el trabajo estudia y analiza una clase de modelos financieros híbridos que integran formalismos estadísticos y dinámica de agentes, y que permiten reproducir con notable fidelidad diversas propiedades estadísticas observadas en los mercados financieros reales.

Palabras clave: Retornos financieros, dinámica de agentes, mecánica estadística no extensiva, distribución q-gaussiana, ecuación de Fokker–Planck, simulación estocástica.

Abstract

This work aims to study the statistical behavior of financial returns through the implementation and analysis of models that integrate microscopic dynamics via stochastic feedback. Two fundamental approaches are considered, one based on Gaussian distributions and the other on q-Gaussian distributions. To develop these approaches, the study begins with a detailed description of geometric Brownian motion, showing how it naturally leads to a Gaussian returns model under classical market assumptions. Subsequently, the nonextensive statistical mechanics proposed by Tsallis is formally introduced, from its theoretical foundations to its implications in the functional form of probability distributions. This allows for a rigorous justification of the q-Gaussian model as a suitable generalization for complex systems with long-range correlations. Additionally, Kirman's model is developed in detail, representing a system with herding behavior and stochastic transitions among three types of agents. This model is formulated continuously through a Fokker–Planck equation, which is then transformed into a Langevin-type stochastic equation. This formulation enables a connection, as proposed by Kononovicius and Gontis, between the agent-based model and the return models through a functional definition of volatility that depends on the dynamic state of the system. Based on this integration, two simulation schemes are designed that use Gaussian and q-Gaussian noise, respectively, both modulated by the volatility generated by the agents' dynamics. The simulated results are compared with high-frequency empirical data corresponding to stocks from the New York, Warsaw, and Vilnius stock exchanges, as well as with daily data on the price of Brent crude oil and the exchange rate between the Colombian peso and the US dollar. It is observed that the q-Gaussian model accurately reproduces the heavy tails that characterize stock returns, while the Gaussian model achieves a better fit for assets such as oil and the dollar, where the distributions present thinner tails. Moreover, a significant scale invariance is evidenced in the simulations, particularly in the Gaussian case, suggesting a robust structure in the distributions generated by the model. A central finding of the study is the existence of an internal limit for the validity of the simulation, resulting from the progressive disappearance of fundamentalist agents in long-term scenarios. This dynamic leads to a divergence in volatility that corresponds to an emergent property of the model itself, which naturally defines its domain of applicability. Altogether, the work studies and analyzes a class of hybrid financial models that integrate statistical formalisms and agent dynamics, enabling the faithful reproduction of various statistical properties observed in real financial markets.

Keywords: Financial returns, agent-based dynamics, nonextensive statistical mechanics, q-Gaussian distribution, Fokker–Planck equation, stochastic simulation.

Contenido

Agradecimientos v

Resumen vii

1. Introducción 2

2. Procesos estocásticos y modelos de difusión 7
2.1. Entropía de Shannon y distribución gaussiana . . . 7
2.1.1. Maximización de la entropía . . . 7
2.2. Movimiento browniano y ecuación de difusión . . . 9
2.2.1. Caminata aleatoria y ecuación de difusión . . . 9
2.3. Proceso de Wiener . . . 10
2.4. Movimiento browniano geométrico . . . 11
2.4.1. Ecuación diferencial estocástica . . . 12
2.4.2. Solución explícita para S_t . . . 12
2.5. Modelo gaussiano de retornos financieros . . . 13

3. Mecánica estadística no extensiva y formalismo de Tsallis 16
3.1. Ecuación de Fokker-Planck no lineal . . . 16
3.2. Entropía de Tsallis y sus propiedades . . . 18
3.2.1. Relación con la entropía de Shannon . . . 18
3.2.2. No extensividad y regla de pseudo-aditividad . . . 19
3.3. Distribución q-gaussiana . . . 20
3.3.1. Derivación variacional y expresión general . . . 20
3.3.2. Límite gaussiano y rol del parámetro q . . . 21
3.3.3. Comportamiento asintótico y colas pesadas . . . 22
3.3.4. Solución estacionaria de la ecuación de Fokker–Planck no lineal . 22
3.4. Modelo q-gaussiano de retornos . . . 23
3.4.1. Generalización del proceso de Wiener . . . 23
3.4.2. Aplicación al modelo de retornos . . . 24

4. Dinámica de agentes y comportamiento gregario 26
4.1. Modelos basados en agentes en econofísica . . . 26
4.1.1. Modelos emergentes sin ecuaciones diferenciales explícitas . . . 26
4.1.2. Modelos con dinámica estocástica explícita . . . 27
4.2. Modelo gregario de Kirman . . . 27
4.2.1. Motivación . . . 28
4.2.2. Formulación estocástica . . . 28

4.2.3. Ecuación diferencial estocástica del sistema 29
4.3. Extensión a un modelo de tres estados para agentes financieros 31
4.3.1. Estados del sistema y transiciones 31
4.3.2. Evolución estocástica de los tres estados 33

5. Integración del enfoque estocástico y el modelo de agentes 35
5.1. Volatilidad como puente entre dinámica macroscópica y microscópica . . 35
5.1.1. Planteamiento funcional de la volatilidad 36
5.1.2. Modelado del log-precio mediante excesos de demanda 36
5.2. Variabilidad de la tasa de eventos τ 38
5.3. Resolución numérica: método de Euler-Maruyama 39
5.4. Ruido externo gaussiano y q-gaussiano 40
5.4.1. Caso gaussiano 41
5.4.2. Caso q-gaussiano 41

6. Metodología y resultados 43
6.1. Metodología 43
6.1.1. Simulación con ruido gaussiano 43
6.1.2. Simulación con ruido q-gaussiano 44
6.1.3. Datos empíricos y tratamiento de la información 44
6.2. Análisis de resultados 45
6.2.1. Límites dinámicos en la simulación del modelo 45
6.2.2. Comparación con datos de acciones de alta frecuencia 47
6.2.3. Evaluación con distintos activos financieros 49

7. Conclusiones 53

A. Apéndice A: Maximización de la entropía de Shannon 56

B. Apéndice B: Maximización de la entropía de Tsallis 58

C. Apéndice C: Deducción de los coeficientes de la solución de la ecuación de Fokker-Planck no lineal 60
C.1. Relación entre Z_q y β por normalización 60
C.2. Reemplazo en la ecuación de Fokker–Planck 61
C.3. Igualación de términos 61
C.4. Cálculo explícito de la constante c 62

D. Apéndice D: Relación entre una ecuación de Fokker-Palck y una ecuación diferencial estocástica. 63

Bibliografía 65

1. Introducción

En las últimas décadas, los mercados financieros han sido ampliamente reconocidos como sistemas complejos cuya dinámica está marcada por la presencia de regularidades estadísticas no triviales. A diferencia de lo que postulan los modelos clásicos basados en hipótesis de eficiencia y racionalidad [1, 2, 3], la evidencia empírica acumulada en una amplia variedad de mercados y periodos temporales ha revelado que los retornos financieros presentan características recurrentes como colas gruesas, asimetrías, agrupamiento de la volatilidad y correlaciones de largo alcance [4, 5, 6, 7]. Estas propiedades, conocidas colectivamente como hechos estilizados, no solo desafían la validez de los supuestos gaussianos y de independencia temporal, sino que también apuntan a la necesidad de marcos teóricos más amplios que integren las complejidades observadas en los datos reales.

En los orígenes del modelado financiero, el comportamiento de los precios fue descrito mediante procesos estocásticos inspirados en la física clásica. Louis Bachelier [1] propuso un modelo de paseo aleatorio para explicar las fluctuaciones en los precios bursátiles. Posteriormente, Paul Samuelson [2] extendió este enfoque en el contexto de la hipótesis de mercado eficiente, para que luego Osborne [8] introdujera los retornos logarítmicos, dando origen al movimiento browniano geométrico y al castillo teórico del modelo Black-Scholes [9] para la valoración de opciones. Con el tiempo, modelos basados en heterocedasticidad condicional como ARCH [10] y GARCH [11] permitieron incorporar explícitamente agrupamiento de volatilidad en la modelación, reflejando que la varianza no permanece constante sino que depende de shocks pasados. Estas aproximaciones han sido exitosas en predicción de volatilidad y en la gestión de riesgo financiero, adaptándose incluso a variantes más complejas como FIGARCH [12] o modelos multifractales con memoria a largo plazo [13]. A pesar de su robustez matemática y relevancia práctica, estas aproximaciones se quedan cortas a la hora de reproducir colas pesadas de los retornos, dependencia temporal de largo alcance y otras irregularidades observadas en datos reales.

Para abordar esas limitaciones, ha emergido un enfoque desde la mecánica estadística no extensiva. A partir del trabajo pionero de Tsallis [14, 15], se generalizó la entropía de Gibbs adaptándola a sistemas con correlaciones de largo alcance o fuera del equilibrio, introduciendo un parámetro q que permite derivar las distribuciones q-gaussianas. En el contexto financiero, estas distribuciones han demostrado una gran capacidad para capturar colas pesadas y ajustar la probabilidad de eventos extremos en retornos, especialmente en datos de alta frecuencia [16, 17]. Estudios posteriores han aplicado estas distribuciones tanto en la modelación de precios de opciones como en fenómenos de difusión anómala, destacando su relevancia en sistemas complejos donde la estadística clásica resulta insuficiente [18, 19]. Así, la estadística no extensiva ha emergido como una herramienta poderosa para describir la leptocurtosis empírica y la persistencia temporal más allá del alcance de los modelos gaussianos tradicionales.

En segunda instancia, los modelos basados en agentes emergen como una alternativa dinámica para explicar la génesis de los patrones empíricos del mercado desde decisiones individuales[20, 21, 22]. En este contexto, el modelo de Kirman [23] sobresale por su capacidad para traducir procesos de imitación y comportamiento gregario en una dinámica estocástica que conecta micro-decisiones con resultados agregados. Originalmente concebido para describir comportamientos de colonias de insectos, el modelo ha sido adaptado al ámbito financiero describiendo transiciones probabilísticas entre estados como optimistas y pesimistas o fundamentalistas [24, 25]. Su formulación permite derivar una versión continua mediante aproximaciones Fokker–Planck y Langevin, lo que facilita su integración con modelos de retornos y volatilidad. Investigaciones recientes han extendido el modelo a tres estados [16], incorporando mayor detalle y asegurando la reproducción de hechos estilizados como colas pesadas y espectro fractal en la densidad energética o espectral. Esta línea teórica representa un avance significativo porque permite articular una descripción matemática formal del mercado donde la volatilidad deja de ser una variable exógena y pasa a depender del estado dinámico de los agentes.

Ante este panorama, Kononovicius y Gontis [16] propusieron un modelo híbrido que integra de forma rigurosa las dinámicas estocásticas de retornos financieros con un sistema subyacente de agentes interactuantes. Esta aproximación plantea una arquitectura en la que la volatilidad del sistema no se considera una entrada exógena ni una simple función temporal, sino que emerge directamente del estado dinámico del modelo de agentes. En particular, dicha volatilidad se define funcionalmente a partir de las fracciones de agentes optimistas, pesimistas y fundamentalistas, permitiendo establecer un vínculo directo entre el comportamiento colectivo de los actores del mercado y la variabilidad estadística de los retornos.

Este tipo de integración entre niveles microscópicos y macroscópicos resulta especialmente valiosa, ya que permite comprender de manera unificada no solo las propiedades estadísticas agregadas, sino también sus mecanismos generadores. Además, al incorporar distribuciones no gaussianas desde el marco de la estadística generalizada, el modelo ofrece una capacidad adicional para reproducir fenómenos observados en mercados reales, particularmente aquellos que desafían las suposiciones del paradigma clásico. En conjunto, este enfoque híbrido representa un avance conceptual importante, proporcionando una estructura flexible y robusta que permite estudiar tanto la dinámica interna del mercado como su manifestación en series temporales de precios, abriendo el camino hacia una comprensión más profunda y realista de la complejidad financiera.

El objetivo central de este trabajo es profundizar en la comprensión y validación teórica del modelo híbrido propuesto por Kononovicius y Gontis [16], el cual integra dinámicas de agentes con ruido estocástico, a través de una formulación rigurosa de sus componentes fundamentales. Para ello, se desarrolla de manera detallada y formal la estructura matemática tanto del enfoque macroscópico basado en distribuciones gaussianas y q-gaussianas, como del modelo microscópico gregario de tres agentes. Esta fundamentación no solo permite justificar desde primeros principios la estructura del modelo, sino también extender su aplicabilidad más allá del mercado accionario, explorando activos financieros adicionales como el precio del barril de petróleo Brent y el tipo de cambio entre el peso colombiano y el dólar estadounidense. Asimismo, se busca estudiar con preci-

sión las propiedades emergentes de la dinámica acoplada, identificando sus características numéricas, sus comportamientos límite y los elementos que determinan su dominio de validez.

En función de este objetivo general, se abordan los siguientes objetivos específicos: (i) presentar una formulación estocástica detallada del modelo gaussiano de retornos a partir del movimiento browniano geométrico; (ii) justificar teóricamente el uso de distribuciones q-gaussianas en contextos financieros mediante los fundamentos de la mecánica estadística no extensiva; (iii) reconstruir paso a paso la estructura matemática del modelo de tres agentes inspirado en Kirman, desde las tasas de transición hasta su expresión continua mediante ecuaciones estocásticas; (iv) estudiar la integración funcional entre los modelos macroscópico y microscópico en el marco de la propuesta de Kononovicius y Gontis, analizando cómo la volatilidad emerge como puente entre ambas escalas; y (v) realizar una simulación numérica del sistema acoplado, comparando los retornos generados con datos empíricos de distintos activos financieros para evaluar la capacidad explicativa del modelo y detectar sus limitaciones operativas.

Para alcanzar estos objetivos, se desarrolló una estructura teórica y computacional que combina herramientas de la estadística, la física y la modelación estocástica. El punto de partida consistió en formular rigurosamente el modelo de retornos gaussianos a partir del movimiento browniano geométrico, bajo los supuestos clásicos de eficiencia y aleatoriedad en los precios. Esta formulación permitió recuperar la conocida dinámica log-normal de los precios y establecer las bases para la posterior generalización. A continuación, se introdujo el marco de la mecánica estadística no extensiva, cuyo fundamento es la entropía generalizada propuesta por Tsallis, que permite obtener distribuciones q-gaussianas. Estas distribuciones son adecuadas para describir fenómenos financieros con colas pesadas y memoria de largo alcance, características que no pueden ser reproducidas por modelos gaussianos. Se detalló su deducción formal a partir de principios variacionales, así como su estructura funcional y propiedades matemáticas.

Posteriormente, se estudió en profundidad el modelo de Kirman en su versión de tres estados, el cual describe la dinámica de transiciones estocásticas entre agentes fundamentalistas, optimistas y pesimistas. Se partió de las tasas de transición entre estados, incorporando efectos de comportamiento gregario, y se construyó la ecuación maestra correspondiente. Esta se expandió hasta obtener una ecuación de Fokker–Planck para las fracciones de agentes, la cual se reescribió como un sistema de ecuaciones estocásticas tipo Langevin. Posteriormente, se implementó la integración funcional entre este modelo de agentes y el modelo estocástico de retornos, siguiendo la propuesta de Kononovicius y Gontis [16]. En esta formulación, la volatilidad deja de ser un parámetro exógeno y se convierte en una variable emergente que depende del log-precio, el cual a su vez se calcula a partir del exceso de demanda agregado de los agentes. También se introdujo una tasa de eventos τ que modula la frecuencia de las transiciones entre estados en función de la dinámica del sistema, lo cual añade un nuevo nivel de realismo al capturar la variabilidad temporal de la actividad del mercado.

A nivel numérico, las ecuaciones estocásticas del sistema fueron resueltas mediante el método de Euler–Maruyama con paso de tiempo adaptativo [26], utilizando una transformación de variables que mejora la estabilidad del algoritmo. La evolución de las

fracciones de agentes permitió construir una serie temporal de volatilidades, las cuales fueron utilizadas para simular retornos financieros con ruido gaussiano y q-gaussiano. En el caso q-gaussiano, los números aleatorios fueron generados mediante el método de la función inversa aplicado a la distribución q-gaussiana estándar con parámetro $q = 1{,}5$, lo cual permite capturar comportamientos extremos y dependencia de largo alcance en los retornos.

Los resultados obtenidos se analizaron en tres niveles. Primero, se identificó que bajo ciertos parámetros, el sistema presenta una desaparición progresiva de los agentes fundamentalistas en escalas de tiempo grandes, lo cual lleva a una divergencia en el log-precio y, por tanto, en la volatilidad. Esta divergencia define de forma natural un límite interno para la validez del modelo. En segundo lugar, se compararon las distribuciones de los retornos simulados con datos empíricos de alta frecuencia de acciones de las bolsas de Nueva York entre 2005 y 2007, Varsovia entre 2000 y 2014, y Vilnius entre 2005 y 2013. Se encontró que el modelo q-gaussiano reproduce con gran fidelidad las colas pesadas observadas en estos mercados, especialmente en los casos más líquidos y desarrollados. Finalmente, se compararon los retornos simulados con series empíricas diarias del precio del petróleo Brent y del tipo de cambio entre el peso colombiano y el dólar estadounidense, ambas comprendidas entre enero de 2010 y enero de 2015. En este caso, el modelo con ruido gaussiano mostró un ajuste superior y se observó una notable invariancia a la escala temporal, reforzando la consistencia estructural del modelo.

Una vez se han descrito los principales resultados obtenidos en este trabajo de grado, se evidencia que lo realizado acá no se limita a replicar la propuesta original de Kononovicius y Gontis [16], sino que se logra un valor agregado significativo mediante una profundización teórica sustancial en cada uno de los componentes fundamentales del modelo. Se presenta un desarrollo completo y detallado del modelo gaussiano de retornos a partir del movimiento browniano geométrico, así como una derivación rigurosa del modelo q-gaussiano basada en los principios de la mecánica estadística no extensiva. Por otro lado, se expone con formalismo matemático el modelo de agentes de Kirman en su versión de tres estados, incluyendo desde las tasas de transición hasta la obtención de sus ecuaciones estocásticas asociadas, lo cual permite una comprensión más profunda de su estructura interna. Esta labor teórica se complementa con un tratamiento cuidadoso en los apéndices, donde se presentan deducciones y detalles técnicos que no suelen encontrarse reunidos en la literatura de forma autocontenida.

Además, el estudio ofrece resultados cuantitativos novedosos que no habían sido reportados anteriormente en trabajos similares. Entre ellos, destaca la identificación de un límite interno de aplicabilidad del modelo, originado por la desaparición progresiva de los agentes fundamentalistas bajo determinadas condiciones, fenómeno que impone de manera natural un dominio de validez temporal a la simulación. También se realiza un análisis detallado del comportamiento del modelo bajo distintos horizontes temporales, demostrando una sorprendente invariancia a escala en ciertas condiciones. Finalmente, se evalúa la capacidad del modelo para ajustarse a activos financieros no bursátiles, como el precio del barril de petróleo Brent y la tasa de cambio entre el peso colombiano y el dólar estadounidense, lo que amplía considerablemente su alcance y relevancia empírica. Estos aportes refuerzan el carácter original de la investigación y su contribución al entendimiento

multiescala del comportamiento de los retornos financieros desde una perspectiva híbrida.

El desarrollo se encuentra estructurado en seis capítulos. Los dos primeros se enfocan al estudio formal de los modelos estocásticos de retornos desde una perspectiva macroscópica. En el primer capítulo se introduce el modelo gaussiano, partiendo del movimiento browniano geométrico, y se presentan sus implicaciones teóricas en el contexto financiero. En el segundo, se expone con rigor la mecánica estadística no extensiva propuesta por Tsallis [14], justificando desde sus fundamentos el uso de distribuciones q-gaussianas como generalización natural del caso clásico. El tercer capítulo se enfoca en la dinámica de agentes, desarrollando en detalle el modelo de Kirman [23] y su generalización a un sistema de tres estados con comportamiento gregario. Posteriormente, en el cuarto capítulo, se integra este modelo microscópico con la descripción macroscópica a través de una definición funcional de la volatilidad, siguiendo el enfoque híbrido propuesto por Kononovicius y Gontis. Allí se analizan los mecanismos de acoplamiento, se presenta la implementación numérica del sistema estocástico y se distinguen los casos gaussiano y q-gaussiano. El quinto capítulo está dedicado a la metodología empleada en las simulaciones, así como a la selección y tratamiento de los datos empíricos. Junto a esto, en este capítulo también se presentan y discuten los resultados obtenidos, estableciendo comparaciones con datos reales de mercados bursátiles, de materias primas y de divisas, y examinando en profundidad las propiedades emergentes del modelo. Posteriormente, en el sexto capítulo se muestran las conclusiones encontradas, analizando la importancia que muestran los resultados dentro del contexto financiero. Por último, en la sección de apéndices se incluyen desarrollos teóricos que complementan y refuerzan el cuerpo principal del trabajo. Se presentan las deducciones completas de los resultados obtenidos mediante la maximización de la entropía de Shannon y de Tsallis, así como el análisis detallado de los coeficientes en la solución de la ecuación de Fokker–Planck no lineal. Además, se establece la conexión formal entre una ecuación de Fokker–Planck y su correspondiente representación estocástica tipo Langevin.

2. Procesos estocásticos y modelos de difusión

2.1. Entropía de Shannon y distribución gaussiana

En la física estadística, uno de los conceptos fundamentales para describir sistemas con muchos grados de libertad es el de entropía. Más allá de su interpretación termodinámica clásica, la entropía también puede entenderse como una medida de cuánta información se tiene sobre el estado exacto de un sistema. Esta perspectiva fue desarrollada a lo largo del siglo XX, particularmente con la formulación de la entropía de Shannon [27], originalmente concebida en el contexto de la teoría de la información, pero con profundas implicaciones para la física.

En su versión discreta, la entropía de Shannon se expresa como:

$$S = -k \sum_{i=1}^{W} p_i \ln p_i, \tag{2-1}$$

donde $\{p_i\}$ es una distribución de probabilidad sobre un conjunto finito de W microestados accesibles, y k es una constante positiva. Esta fórmula cuantifica la cantidad de información faltante al no conocer cuál de los microestados describe realmente al sistema. A mayor dispersión o desorden de la distribución, mayor será el valor de S.

Cuando se considera una variable continua u, la entropía se generaliza como:

$$S = -k \int du\, p(u) \ln p(u), \tag{2-2}$$

con $p(u)$ como una densidad de probabilidad normalizada. Esta expresión conserva la interpretación de S como una medida de la incertidumbre estadística sobre el valor de u, y constituye una herramienta clave en la formulación moderna de la mecánica estadística.

2.1.1. Maximización de la entropía

Uno de los principios fundamentales que se asocian a esta entropía es el de máxima entropía, según el cual, ante un conocimiento parcial del sistema, la distribución que mejor representa ese conocimiento es aquella que maximiza S bajo las restricciones impuestas [28]. Este principio permite derivar leyes de probabilidad sin necesidad de asumir hipótesis microscópicas adicionales.

Para ilustrar este enfoque, se plantea el problema de encontrar la distribución $p(u)$

que maximiza S bajo las condiciones de normalización, media y varianza fija, las cuales corresponden respectivamente con

$$\int du\, p(u) = 1, \qquad \int du\, (u - u_M) p(u) = 0, \qquad \int du\, (u - u_M)^2 p(u) = \sigma^2. \tag{2-3}$$

Este problema se resuelve mediante el método de los multiplicadores de Lagrange, cuyo desarrollo completo se presenta en el apéndice A. El resultado es la distribución gaussiana:

$$P(u) = \frac{e^{-\beta(u-u_M)^2}}{Z}, \tag{2-4}$$

donde $\beta = 1/(2\sigma^2)$ y la constante de normalización corresponde con

$$Z = \int du\, e^{-\beta(u-u_M)^2} = \left(\frac{\pi}{\beta}\right)^{1/2}. \tag{2-5}$$

Esta distribución corresponde a una gaussiana centrada en u_M y representa la distribución de probabilidad que resulta al asumir únicamente información sobre la media y la varianza. En la figura 2-1 se ilustra cómo varía su forma al modificar el parámetro β que controla la anchura de la distribución y, por tanto, el nivel de fluctuaciones permitido.

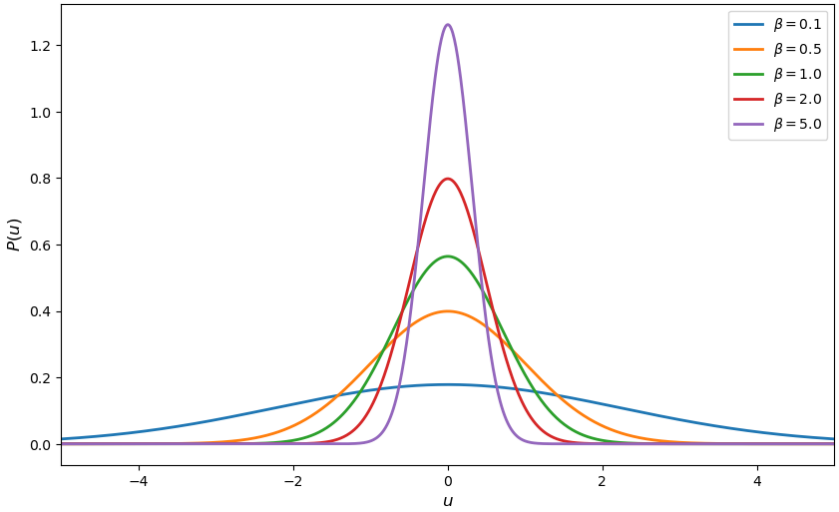

Figura 2-1.: Distribución gaussiana con media 0 para diferentes valores de β.

La distribución gaussiana aparece en numerosos contextos físicos, donde describe las fluctuaciones de sistemas en equilibrio térmico [29], el comportamiento de partículas libres sometidas a potenciales armónicos [30], etc. Su forma funcional, decreciente exponencialmente en el cuadrado de la variable, refleja la alta probabilidad de estados cercanos al valor medio y la rápida disminución de la probabilidad para eventos extremos.

El hecho de que esta distribución emerja de la maximización de la entropía bajo

restricciones sencillas demuestra el impacto del modelo. Este enfoque será retomado y generalizado en capítulos posteriores, donde se explorarán extensiones del concepto de entropía que permiten describir sistemas alejados del equilibrio o con dinámicas más complejas, como ocurre en ciertos sistemas financieros o físicos con colas pesadas.

2.2. Movimiento browniano y ecuación de difusión

El movimiento browniano constituye uno de los modelos fundamentales para describir la evolución temporal de sistemas aleatorios. Representa el comportamiento errático de una partícula sometida a múltiples interacciones microscópicas no observables de forma individual, pero cuyo efecto colectivo puede modelarse estadísticamente. Aunque su primera observación fue realizada por Robert Brown en 1827, no fue hasta 1905 que Albert Einstein proporcionó una descripción teórica basada en argumentos probabilísticos, interpretando el movimiento como el resultado de colisiones con las moléculas del fluido [31]. Esta formulación permitió conectar directamente los parámetros observables del movimiento con la estructura molecular de la materia, y fue confirmada experimentalmente por Jean Perrin, consolidando la hipótesis atómica [32].

El modelo de Einstein cambió la forma de entender los procesos aleatorios al pasar de las trayectorias individuales, a estudiar la evolución de la función de densidad de probabilidad $p(x,t)$, que describe la probabilidad de encontrar una partícula en la posición x en el instante t. Esta función codifica toda la información accesible sobre el sistema en ausencia de un conocimiento determinista completo.

2.2.1. Caminata aleatoria y ecuación de difusión

El movimiento browniano puede entenderse como el límite continuo de una caminata aleatoria: a cada instante, una partícula sufre un pequeño desplazamiento aleatorio, independiente de su historia pasada. Bajo ciertas condiciones de simetría e independencia, al tomar pasos cada vez más pequeños y frecuentes, el proceso converge a una dinámica gobernada por la ecuación diferencial:

$$\frac{\partial}{\partial t}p(x,t) = D\frac{\partial^2}{\partial^2 x}p(x,t), \tag{2-6}$$

conocida como ecuación de difusión o ecuación de Fokker–Planck lineal. El parámetro $D > 0$ es el coeficiente de difusión, que mide la rapidez con la que se dispersa la probabilidad en el espacio.

Esta ecuación tiene como solución la distribución gaussiana con $\beta = 1/4Dt$ y media $u_M = 0$, cuando la condición inicial es una delta de Dirac $p(x,0) = \delta(x)$. Con esto, la ecuación 2-4 queda como:

$$p(x,t) = \frac{1}{\sqrt{4\pi Dt}}\exp\left(-\frac{x^2}{4Dt}\right). \tag{2-7}$$

Esta solución describe cómo, a medida que transcurre el tiempo, la probabilidad

de encontrar la partícula se redistribuye en el espacio. Comportamiento que implica que no hay una descripción de una trayectoria individual, sino una evolución estadística de muchas partículas, tal y como se muestra en la figura 2-2. En este gráfico, cada curva representa una posible trayectoria simulada de una partícula bajo movimiento browniano, y el conjunto de ellas sugiere que, aunque cada trayectoria es impredecible, su conjunto obedece a una estructura regular que se vuelve cada vez más ancha a medida que avanza el tiempo. La explicación física detrás de esta solución es que la partícula no tiene una dirección preferente, pero su incertidumbre sobre la posición crece con el tiempo.

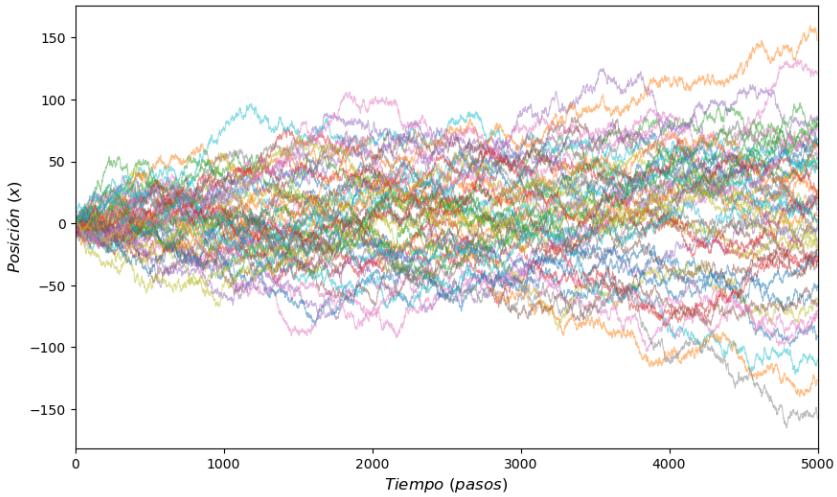

Figura 2-2.: Trayectorias simuladas de partículas independientes en movimiento browniano.

2.3. Proceso de Wiener

El proceso de Wiener representa una formulación matemática rigurosa del movimiento browniano y constituye el modelo estocástico base a partir del cual se construyen la mayoría de las ecuaciones diferenciales estocásticas. Esta herramienta, desarrollada formalmente por Norbert Wiener [33], permite describir trayectorias continuas que presentan una variabilidad aleatoria inherente, sin necesidad de hacer referencia a un modelo microscópico específico.

Este proceso se define como una familia de variables aleatorias $\{W(t)\}_{t\geq 0}$ que satisface tres propiedades fundamentales:

- $W(0) = 0$, es decir, todas las trayectorias comienzan en el origen.
- Los incrementos son independientes, con lo cual, al tener tiempos $0 \leq t_1 < t_2 < \cdots < t_n$, los incrementos $W(t_{i+1}) - W(t_i)$ son mutuamente independientes.
- Los incrementos $W(t+s) - W(s) \sim \mathcal{N}(0, \Delta t)$ para todo $s, \Delta t \geq 0$, lo que implica que el proceso tiene incrementos gaussianos con varianza creciente de forma lineal.

Esta combinación de características asegura que el proceso es estacionario en sus incrementos, gaussiano y con trayectorias continuas con probabilidad uno. A su vez, este grupo de propiedades hace que el proceso de Wiener capture la esencia del movimiento browniano observado en la naturaleza, en donde cada trayectoria es impredecible, pero el comportamiento estadístico del conjunto de trayectorias puede caracterizarse de forma precisa.

Un comportamiento que distingue al proceso de Wiener de otros modelos estocásticos es la no diferenciabilidad de sus trayectorias. Aunque estas son continuas en todo tiempo, su variación es tan irregular que la derivada no existe en sentido clásico en ningún punto, con probabilidad uno. Esta característica fue explorada a profundidad en el desarrollo de la teoría moderna de procesos estocásticos y da lugar al concepto de variación cuadrática. Gracias a esta estructura matemática, el proceso de Wiener puede entenderse como el ruido blanco continuo que se utiliza en las ecuaciones diferenciales estocásticas, aunque su formulación es mucho más regular que la noción informal de "ruido puro".

Otra propiedad importante es que el proceso de Wiener constituye una martingala. Esto significa que su valor esperado futuro, condicionado a la información disponible hasta el tiempo actual, es igual al valor presente. En otras palabras, el proceso no tiene una tendencia sistemática a crecer ni a decrecer, lo que lo convierte en un modelo natural para describir situaciones de incertidumbre sin sesgo. Esta propiedad es de especial relevancia en finanzas, donde se ha utilizado como base para modelar mercados eficientes y construir derivados como el modelo de Black–Scholes–Merton [34].

Finalmente, el proceso de Wiener actúa como piedra angular de la teoría de ecuaciones diferenciales estocásticas. Una gran clase de sistemas dinámicos afectados por fluctuaciones aleatorias puede modelarse mediante expresiones del tipo

$$dX_t = \mu(X_t, t)dt + \sigma(X_t, t)dW_t, \tag{2-8}$$

donde el término μ representa el componente determinista (o deriva) y el término σdW_t incorpora una perturbación aleatoria basada en el proceso de Wiener. Esta formulación permite estudiar sistemas que combinan dinámica regular con ruido o con dinámicas estocásticas individualmente impredecibles.

2.4. Movimiento browniano geométrico

El movimiento browniano geométrico constituye uno de los procesos estocásticos más utilizados para describir fenómenos que evolucionan de forma multiplicativa en el tiempo. A diferencia del movimiento browniano clásico, que se construye como un proceso estocástico aditivo con incrementos normales, el modelo geométrico describe trayectorias positivas cuya evolución depende proporcionalmente de su valor actual. Este tipo de comportamiento es característico de sistemas donde los cambios se expresan en términos relativos o porcentuales, y no absolutos.

2.4.1. Ecuación diferencial estocástica

La deducción del movimiento browniano geométrico parte de una modificación natural del movimiento browniano simple. Supóngase una variable estocástica S_t interpretada como el valor de un sistema en el tiempo t, que sufre fluctuaciones aleatorias con una tasa de crecimiento proporcional a su valor. En ese caso, se propone que su dinámica esté regida por una ecuación diferencial estocástica (EDE) del tipo:

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \tag{2-9}$$

donde $\mu \in \mathbb{R}$ representa la tasa de crecimiento promedio, $\sigma > 0$ es la volatilidad (o intensidad del ruido), y W_t es un proceso de Wiener. Esta ecuación, conocida como ecuación del proceso estocástico movimiento browniano geométrico, puede interpretarse como la versión estocástica de un crecimiento exponencial clásico, en el que el primer término corresponde a la evolución determinista y el segundo introduce fluctuaciones aleatorias multiplicativas.

Una propiedad inmediata de este proceso estocástico es que, a diferencia del movimiento browniano clásico, el proceso S_t permanece positivo, con probabilidad uno si parte de un valor positivo. Esto se debe a que el ruido se incorpora de forma proporcional al valor actual, evitando cruces negativos.

2.4.2. Solución explícita para S_t

Para resolver la ecuación 2-9, se recurre al cálculo estocástico, específicamente a la fórmula de Itô, que permite derivar funciones de procesos estocásticos [35]. Dado que $S_t > 0$, se considera la variable auxiliar $X_t = \ln S_t$, y se busca la ecuación diferencial estocástica que sigue X_t.

La fórmula de Itô para una función $f(S_t)$ dos veces diferenciable indica que:

$$df(S_t) = f'(S_t)dS_t + \frac{1}{2}f''(S_t)(dS_t)^2. \tag{2-10}$$

Esta ecuación muestra que cuando se tienen variables estocásticas, sus diferenciales no son siempre exactamente 0 al elevarse al cuadrado. Por eso, dicha ecuación no solo limita la expansión del diferencial al primer orden, como se hace en el cálculo clásico, sino que se lleva hasta segundo orden.

Ahora, para el caso en que $f(S_t) = \ln S_t$, tenemos:

$$f'(S_t) = \frac{1}{S_t}, \qquad f''(S_t) = -\frac{1}{S_t^2}. \tag{2-11}$$

Sustituyendo 2-11 en 2-10, se obtiene:

$$d(\ln S_t) = \frac{1}{S_t}dS_t - \frac{1}{2S_t^2}(dS_t)^2. \tag{2-12}$$

A continuación, se calcula el cuadrado diferencial:

$$(dS_t)^2 = (\mu S_t dt + \sigma S_t dW_t)^2 = \mu^2 S_t^2 dt^2 + 2\mu\sigma S_t^2 dt\ dW_t + \sigma^2 S_t^2 (dW_t)^2. \tag{2-13}$$

Tal y como se comentó previamente, en el cálculo estocástico se tiene que $dt^2 \approx 0$, $dt\ dW_t \approx 0$ y $(dW_t)^2 = dt$. Con esto, la ecuación 2-13 quedaría de la siguiente forma:

$$(dS_t)^2 = \sigma^2 S_t^2 dt. \tag{2-14}$$

Y sustituyendo en 2-12

$$d(\ln S_t) = \frac{1}{S_t}(\mu S_t dt + \sigma S_t dW_t) - \frac{1}{2S_t^2}(\sigma^2 S_t^2 dt) \tag{2-15}$$

$$= \left(\mu - \frac{1}{2}\sigma^2\right) dt + \sigma dW_t. \tag{2-16}$$

Esta ecuación presenta coeficientes constantes, con lo cual se puede integrar para $\ln S_t$ entre los tiempos 0 y t:

$$\ln S_t - \ln S_0 = \left(\mu - \frac{1}{2}\sigma^2\right) t + \sigma W_t. \tag{2-17}$$

Por lo que la solución para S_t sería

$$S_t = S_0 \exp\left[\left(\mu - \frac{1}{2}\sigma^2\right) t + \sigma W_t\right]. \tag{2-18}$$

Esta expresión muestra que S_t es una exponencial de un proceso gaussiano, por lo que se trata de un proceso log-normal. A partir de esta solución también se puede observar que $S_t > 0$ siempre que $S_0 > 0$, y que las trayectorias son continuas, aunque no diferenciables.

2.5. Modelo gaussiano de retornos financieros

Los mercados financieros constituyen un entorno altamente dinámico en el que se intercambian activos como acciones, divisas, bonos o materias primas. El comportamiento colectivo de compradores y vendedores genera una evolución continua de los precios de estos activos, lo que ha motivado el desarrollo de modelos matemáticos capaces de describir dichos movimientos [9]. Comprender la naturaleza estocástica de los precios y sus fluctuaciones es fundamental tanto para el análisis teórico como para la toma de decisiones prácticas en economía y finanzas [1, 9, 36].

Desde un punto de vista cuantitativo, el precio de un activo financiero, denotado por S, se modela como una variable positiva que varía en el tiempo según diversas influencias, incluyendo información externa, decisiones individuales y efectos de mercado. Uno de los enfoques más influyentes y utilizados para modelar esta evolución es haciendo

uso del movimiento browniano geométrico presentado anteriormente, el cual fue introducido formalmente por Osborne [8] como extensión del trabajo pionero de Bachelier [1]. Este modelo se apoya en la hipótesis de que los precios evolucionan de manera continua y que sus variaciones relativas pueden representarse mediante un proceso estocástico multiplicativo.

En esta formulación, el precio S de un activo en un tiempo t se describe por la ecuación diferencial estocástica 2-9, quedando de la siguiente manera:

$$dS(t) = \mu(t)S(t)dt + \sigma(t)S(t)dW_t, \tag{2-19}$$

donde $\mu(t)$ representa la tasa promedio de crecimiento del precio dependiente del tiempo y σ es la volatilidad también dependiente del tiempo. Como se mostró previamente, esta ecuación conduce a una solución explícita del tipo:

$$S(t) = S(0)\ \exp\left[\left(\mu(t) - \frac{1}{2}\sigma(t)^2\right)t + \sigma(t)W_t\right], \tag{2-20}$$

lo que implica que el precio sigue un proceso log-normal, es decir, su logaritmo es una variable normalmente distribuida.

Una variable de particular interés en finanzas no es el precio en sí, sino su variación relativa en el tiempo. Para capturar esto se introduce el retorno de un activo, definido en un intervalo temporal T como:

$$R_t(T) = \frac{S(t+T) - S(t)}{S(t)}. \tag{2-21}$$

Aunque esta forma de expresar el retorno es útil en ciertos contextos, en la práctica se prefiere trabajar con su versión logarítmica:

$$r_t(T) = \ln\left(\frac{S(t+T)}{S(t)}\right), \tag{2-22}$$

conocido como log-retorno. Esta variable tiene propiedades matemáticas deseables, como la aditividad temporal $r_t(T_1 + T_2) = r_t(T_1) + r_{t+T_1}(T_2)$, y se ajusta mejor al análisis estadístico. Además, cuando el retorno es pequeño, como suele ocurrir en escalas temporales cortas, el log-retorno y el retorno son aproximadamente iguales, ya que $\ln(1+r) \approx r$ cuando r es pequeño. Esta equivalencia justifica el uso indistinto del retorno y del log-retorno en escalas pequeñas, aunque el log-retorno continúa siendo preferido por sus propiedades algebraicas, incluso en marcos continuos.

Usando la expresión 2-19, se puede calcular directamente el log-retorno en un intervalo T:

$$r_t(T) = \left(\mu(t) - \frac{1}{2}\sigma(t)^2\right)T + \sigma(t)W_T. \tag{2-23}$$

Como $W_T \sim \mathcal{N}(0, T)$, se concluye que el log-retorno es una variable aleatoria nor-

malmente distribuida, con media $(\mu - \frac{1}{2}\sigma^2)T$ y varianza $\sigma^2 T$. Sabiendo esto, su función de densidad de probabilidad puede escribirse como:

$$P(r_t(T)) = \frac{1}{\sqrt{2\pi\sigma(t)^2 T}} \exp\left\{ -\frac{[r_t(T) - \mu(t)T + \frac{1}{2}\sigma(t)^2 T]^2}{2\sigma(t)^2 T} \right\}, \tag{2-24}$$

constituyéndose así el modelo gaussiano de retornos financieros.

Aunque esta hipótesis de normalidad ha sido fundamental en el desarrollo de la teoría financiera moderna, se mostrará en capítulos posteriores que numerosos estudios empíricos han mostrado que los retornos reales de los activos presentan desviaciones significativas respecto a la gaussiana [36]. Estas observaciones han motivado el desarrollo de modelos alternativos, como los basados en la mecánica estadística no extensiva [14, 15], que permiten capturar la presencia de colas pesadas, entre otras características empíricas de los sistemas.

3. Mecánica estadística no extensiva y formalismo de Tsallis

Los modelos estocásticos clásicos en física y finanzas, como los vistos previamente, asumen que las fluctuaciones siguen una dinámica lineal gobernada por ruido con distribución normal. Esta suposición conduce naturalmente a soluciones gaussianas de la ecuación de Fokker–Planck, que describen con éxito muchos sistemas físicos simples [37]. Sin embargo, al analizar sistemas complejos como los mercados financieros reales, se observan desviaciones sistemáticas respecto a este comportamiento: colas pesadas en las distribuciones de retorno, intermitencia, memoria de largo alcance y escalamiento anómalo de las fluctuaciones [4, 5, 7, 38]

Estas observaciones han motivado el desarrollo de generalizaciones que permitan modelar fenómenos de difusión anómala y que, a su vez, sean consistentes con una estadística diferente a la gaussiana. Una de las propuestas más destacadas en este sentido es la mecánica estadística no extensiva formulada por Constantino Tsallis [14], en donde propone una entropía generalizada y la relaciona con una ecuación de Fokker-Planck no lineal.

3.1. Ecuación de Fokker-Planck no lineal

Como se anticipó, una forma de extender la teoría difusiva clásica para capturar fenómenos anómalos consiste en introducir una no linealidad en la ecuación de Fokker–Planck [39]. Esta generalización se sustenta en la necesidad de modelar dinámicas en las cuales la evolución probabilística del sistema no solo depende de las propiedades locales del espacio o del tiempo, sino también del valor de la propia distribución de probabilidad.

En ausencia de fuerzas externas, una formulación típica para fenómenos anómalos utiliza una ecuación de la forma:

$$\frac{\partial}{\partial t}p(x,t) = D\frac{\partial^2}{\partial^2 x}[p(x,t)]^{\nu}, \tag{3-1}$$

donde $D > 0$ es el coeficiente de difusión y $\nu \in \mathbb{R}$ es un exponente que introduce la no linealidad. Este tipo de ecuación ha sido estudiada en diversos contextos, en plasmas y transporte en medios porosos [40], turbulencia [41] o dinámica de precios en mercados financieros [16, 17, 24, 25], todos ellos caracterizados por desviaciones respecto al comportamiento gaussianamente difusivo.

La presencia del exponente ν modifica el mecanismo de propagación de la distribución: en lugar de difundirse con una intensidad homogénea, el sistema difunde en función

de la magnitud de la probabilidad local. Esta modificación tiene una interpretación física directa si se reescribe el término difusivo utilizando la regla de la cadena:

$$D\frac{\partial^2}{\partial^2 x}[p(x,t)]^\nu = \frac{\partial}{\partial x}(D\nu[p(x,t)]^{\nu-1}\frac{\partial}{\partial x}[p(x,t)]) \tag{3-2}$$

$$= \frac{\partial}{\partial x}(D_{eff}\frac{\partial}{\partial x}[p(x,t)]), \tag{3-3}$$

donde se define un coeficiente de difusión efectivo dependiente de la posición y el tiempo:

$$D_{eff}(p) = D\nu[p(x,t)]^{\nu-1}. \tag{3-4}$$

Esto revela que la ecuación, aunque estructuralmente similar a la versión lineal, incorpora una respuesta localmente adaptativa, en donde la difusión ocurre con distinta intensidad dependiendo del valor de $p(x,t)$ en cada punto. Esta dependencia da lugar a tres regímenes fundamentales:

- **Difusión normal:** cuando $\nu = 1$, se recupera la ecuación clásica con difusión constante. El proceso es homogéneo y lineal, y su solución es una distribución gaussiana.

- **Superdifusión o difusión reforzada:** cuando $\nu > 1$, la difusión es más intensa en regiones donde la densidad de probabilidad es alta. Esto sugiere una dinámica en la que las regiones con mayor concentración de probabilidad tienden a expandirse más rápido, lo cual puede interpretarse como un efecto de cooperación local.

- **Subdifusión o difusión en eventos raros:** cuando $\nu < 1$, el coeficiente de difusión es mayor donde $p(x,t)$ es pequeño, es decir, en las colas de la distribución. En este régimen, la dinámica favorece la dispersión hacia regiones de baja densidad, generando una probabilidad significativamente mayor de observar eventos alejados de la media. Este comportamiento es particularmente relevante en el modelado de fenómenos con colas pesadas o fluctuaciones extremas, como las que se encuentran en mercados financieros [16, 17].

Desde un punto de vista físico, este tipo de no linealidad permite capturar el hecho de que en muchos sistemas reales la tasa de difusión no es constante ni universal, sino que depende del estado local del sistema. En otras palabras, el sistema modula su propia dinámica de difusión, generando patrones no gaussianos, asimetrías o incluso estructuras persistentes en el tiempo.

En el contexto del modelado de retornos financieros, este formalismo permite introducir de forma natural una probabilidad más alta para eventos extremos (caídas o subidas abruptas), evitando así la subestimación sistemática que presentan los modelos gaussianos. Es justamente este tipo de comportamiento el que se pretende capturar con soluciones no lineales de la ecuación de Fokker–Planck, las cuales, como se verá más adelante, se vinculan estrechamente con la estadística no extensiva propuesta por Tsallis.

3.2. Entropía de Tsallis y sus propiedades

En el contexto de sistemas complejos caracterizados por estructuras multifractales o correlaciones de largo alcance, Tsallis propuso en 1988 [14] una generalización de la entropía clásica que extiende el formalismo de la teoría de la información. Su propuesta se expresa como:

$$S_q \equiv k\frac{1-\sum_{i=1}^{W} p_i^q}{q-1}, \tag{3-5}$$

con $q \in \mathbb{R}$, $k > 0$ y p_i una distribución de probabilidad normalizada ($\sum_{i=1}^{W} p_i = 1$). Esta formulación introduce el parámetro q, que controla el grado de no extensividad del sistema.

3.2.1. Relación con la entropía de Shannon

Esta entropía, al ser una generalización de la entropía de Shannon, presenta la propiedad de que cuando $q \to 1$ se recupera la entropía usual como caso límite. Dicha recuperación puede demostrarse fácilmente mediante una expansión de Taylor. Utilizando que:

$$p_i^{q-1} = e^{(q-1)\ln p_i} \approx 1 + (q-1)\ln p_i + \mathcal{O}((q-1)^2). \tag{3-6}$$

De acá y despreciando los términos de orden 2 cuando $q \to 1$, se obtiene:

$$\sum_{i=1}^{W} p_i^q \approx \sum_{i=1}^{W} p_i(1+(q-1)\ln p_i) = 1 + (q-1)\sum_{i=1}^{W} p_i \ln p_i. \tag{3-7}$$

Reemplazando el 3-5 se deduce:

$$\lim_{q\to 1} S_q = -k\sum_{i=1}^{W} p_i \ln p_i, \tag{3-8}$$

mostrando de esta forma que la entropía de Tsallis es efectivamente una extensión coherente de la entropía de Shannon.

Así, el rol del parámetro q pasa a ser fundamental y su influencia sobre la forma funcional de la entropía puede visualizarse claramente en el caso más simple, cuando el sistema posee solo dos posibles configuraciones. Si se considera $W = 2$, entonces basta con una sola probabilidad libre $p \in [0, 1]$, ya que la segunda está determinada por normalización. En este escenario, la expresión de S_q se reduce a una función de una sola variable, lo que permite representar gráficamente su comportamiento para diferentes valores de q. La figura 3-1 muestra cómo la curvatura y el valor máximo de la entropía cambian en función de q, ilustrando la forma en que esta generalización captura distintos regímenes estadísticos.

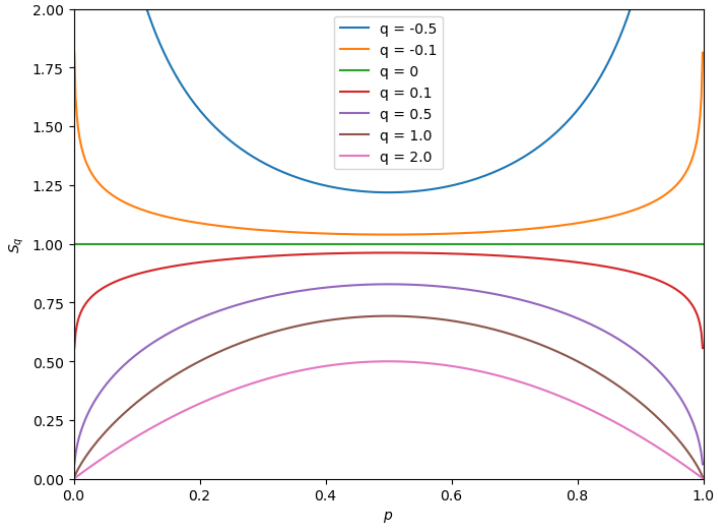

Figura 3-1.: Entropía de Tsallis para $W = 2$ en función de una probabilidad libre, para distintos valores de q.

Además, existe una versión continua de esta entropía que será de utilidad en secciones posteriores:

$$S_q = k\frac{1 - \int du\, p(u)^q}{q - 1}, \tag{3-9}$$

la cual conserva todas las propiedades estructurales de su contraparte discreta y será utilizada para derivar distribuciones de probabilidad en espacios continuos, más específicamente en el modelo de retornos.

3.2.2. No extensividad y regla de pseudo-aditividad

Una característica central de la entropía de Tsallis es su no extensividad, es decir, el hecho de que no cumple la propiedad aditiva típica de la entropía de Shannon. En particular, para dos sistemas estadísticamente independientes A y B, se verifica la regla de pseudo-aditividad:

$$S_q(A + B)/k = S_q(A)/k + S_q(B)/k + (1 - q)[S_q(A)/k][S_q(B)/k], \tag{3-10}$$

donde A y B son dos subsistemas independientes, es decir, $p_{ij}(A + B) = p_i(A)p_j(B)$. Esa propiedad se deduce directamente al aplicar la definición de S_q a sistemas compuestos y refleja que, para $q \neq 1$, la entropía del todo no es simplemente la suma de las partes.

El término adicional, proporcional a $(1 - q)$, captura la existencia de correlaciones implícitas o fluctuaciones globales que no pueden ser representadas por una estadística extensiva. En particular:

- Si $q < 1$, el sistema muestra superaditividad: la entropía del todo es mayor que la suma de las partes.

- Si $q > 1$, el sistema exhibe subaditividad: la entropía del conjunto es menor.

Estas desviaciones del comportamiento extensivo reflejan la presencia de estructuras globales o correlaciones no triviales entre elementos del sistema, y otorgan al formalismo no extensivo una capacidad descriptiva más rica en contextos donde las hipótesis del equilibrio clásico resultan inadecuadas.

3.3. Distribución q-gaussiana

La entropía de Tsallis no solo permite caracterizar sistemas con propiedades estadísticas no convencionales, sino que además conduce, mediante un principio variacional, a una familia de distribuciones de probabilidad con propiedades adecuadas para describir fenómenos con colas pesadas [15]. Estas distribuciones, conocidas como q-gaussianas, emergen naturalmente al maximizar S_q bajo restricciones apropiadas de normalización, media y varianza generalizadas, y constituyen soluciones estacionarias de ciertas ecuaciones de difusión no lineal.

3.3.1. Derivación variacional y expresión general

Para realizar la deducción de la familia de distribuciones q-gaussianas se debe maximizar la entropía de Tsallis bajo el conjunto de restricciones canónicas, lo cual conduce a una expresión funcional que generaliza el tratamiento gaussiano. Las condiciones impuestas son:

$$\int du\, p = 1, \qquad \int du\, (u - u_M) p^q = 0, \qquad \int du\, (u - u_M)^2 p^q = \sigma^2, \tag{3-11}$$

donde u_M representa la media generalizada y σ^2 la varianza generalizada. Algo importante a resaltar es que cuando $q \to 1$ estas condiciones resultan siendo las mismas que se utilizan para obtener la distribución gaussiana.

Ahora, aplicando el método de los multiplicadores de Lagrange, desarrollado a profundidad en el apéndice B, se obtiene como resultado la forma general de la distribución:

$$P_q(u) = \frac{[1 - \beta(1-q)(u - u_M)^2]_+^{1/(1-q)}}{Z_q}, \tag{3-12}$$

donde Z_q es la constante de normalización, $\beta > 0$ actúa como parámetro inversamente proporcional a la varianza, y la notación $[]_+$ denota que el soporte de la distribución está restringido a los valores para los cuales el argumento es no negativo.

Dado que los sistemas empíricos de interés, como los retornos financieros, presentan simetría alrededor de cero [38], se asume sin pérdida de generalidad que $u_M = 0$, reduciendo la expresión 3-12 a:

$$P_q(x) = \frac{[1 - \beta(1-q)x^2]_+^{1/(1-q)}}{Z_q}. \tag{3-13}$$

3.3.2. Límite gaussiano y rol del parámetro q

La distribución q-gaussiana tiene un comportamiento relevante, el cual es que recupera la distribución normal como caso límite cuando $q \to 1$, en consistencia con el comportamiento de la entropía de Tsallis. Para mostrarlo explícitamente, se toma el logaritmo de la ecuación 3-13:

$$\ln\left(P_q(x)\right) = \frac{1}{1-q}\ln\left[1-(1-q)\beta x^2\right]. \tag{3-14}$$

Expandido en series de Taylor:

$$\ln\left(1-y\right) = -y - \frac{y^2}{2} - \mathcal{O}(y^3), \quad \text{con } y = (1-q)\beta x^2, \tag{3-15}$$

se obtiene:

$$\ln P_q(x) \approx -\beta x^2 - \frac{(1-q)\beta^2 x^4}{2}. \tag{3-16}$$

Por lo tanto, cuando $q \to 1$:

$$\lim_{q\to 1} \ln P_q(x) = -\beta x^2 \quad \to \quad \lim_{q\to 1} P_q(x) = e^{-\beta x^2}, \tag{3-17}$$

que corresponde a la distribución gaussiana.

Este resultado evidencia el papel clave del parámetro q: regula el grado de desviación respecto a la gaussiana. Como se observa en la Figura 3-2, cuando $q < 1$, la distribución presenta colas finitas y más delgadas (régimen superaditivo), mientras que para $q > 1$, aparecen colas más gruesas (régimen subaditivo), consistentes con los patrones observados en datos financieros.

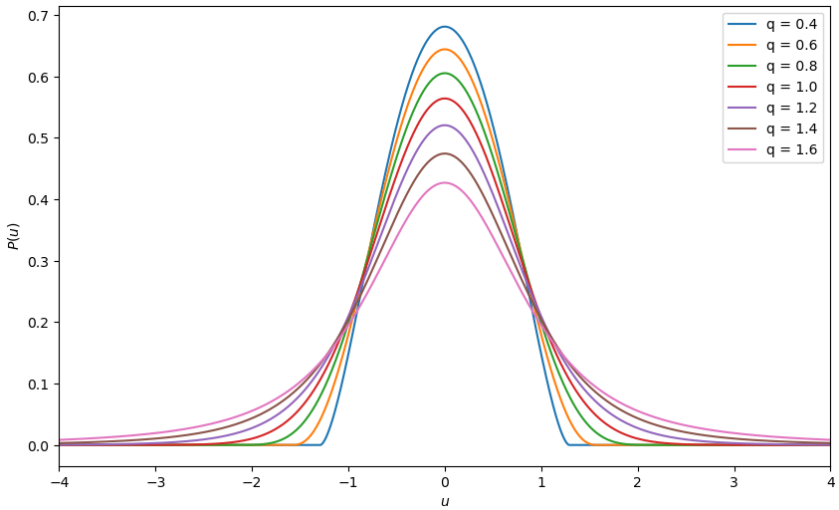

Figura 3-2.: Distribuciones q-gaussianas para $\beta = 1$ y distintos valores de q.

3.3.3. Comportamiento asintótico y colas pesadas

Una de las propiedades más destacables de la q-gaussiana es el comportamiento de sus colas. En particular, para $q > 1$, la distribución presenta un decaimiento asintótico tipo ley de potencias:

$$P_q(x) \sim |x|^{2/(1-q)} \quad \text{para } |x| \to \infty, \tag{3-18}$$

lo cual contrasta fuertemente con el decaimiento exponencial de la gaussiana. Esta propiedad es de particular relevancia para describir sistemas en los que los eventos extremos (fluctuaciones grandes) son mucho más probables que en modelos clásicos.

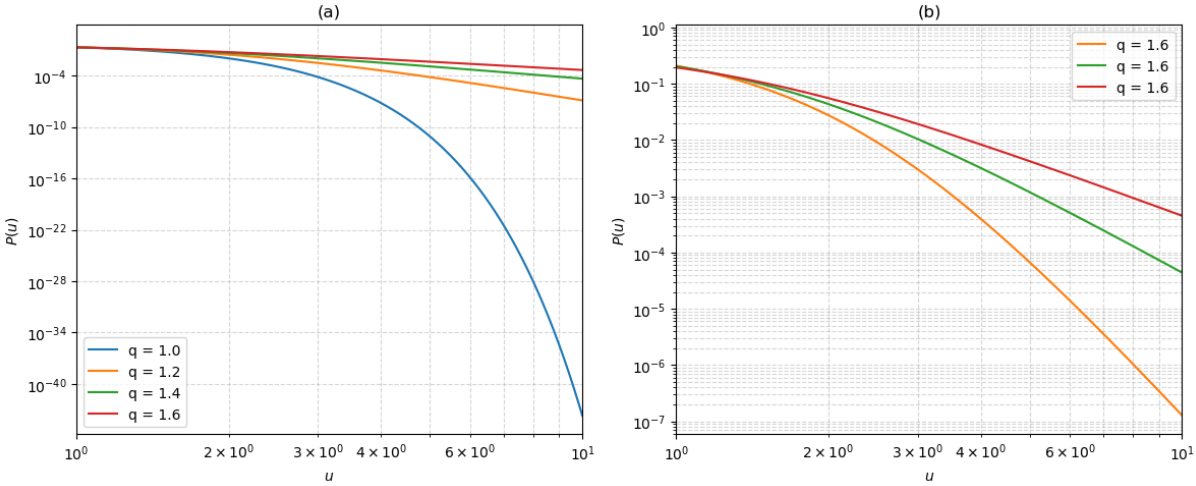

Figura 3-3.: (a) Comparación entre distribuciones q-gaussianas y la gaussiana. (b) Distribuciones q-gaussianas con distintos valores de q en escala logarítmica.

La figura 3-3 ilustra este comportamiento. En la parte (a), se comparan distribuciones q-gaussianas con una gaussiana en escala logarítmica, mostrando cómo las colas de las primeras se mantienen elevadas y con una forma lineal. Esto contrasta claramente con el decaimiento exponencial de la distribución gaussiana. Por otra parte, en la parte (b), se observa que todas las distribuciones q-gaussianas presentan un decaimiento lineal en dicha escala, confirmando su estructura de ley de potencias.

3.3.4. Solución estacionaria de la ecuación de Fokker–Planck no lineal

Tal como se analizó previamente, una generalización no lineal de la ecuación de Fokker–Planck permite capturar regímenes de difusión anómala. Si se considera la siguiente ecuación:

$$\frac{\partial}{\partial t} p(x,t) = \frac{1}{2} \frac{\partial^2}{\partial^2 x} [p(x,t)]^{2-q}, \tag{3-19}$$

se tendría el caso particular en el que se asume una relación entre el exponente de no linealidad y el parámetro de Tsallis del tipo $\nu = 2 - q$. Esta identificación conecta la naturaleza difusiva del sistema con su comportamiento estadístico no extensivo, estableciendo una correspondencia entre la subdifusión ($\nu < 1$) con las colas pesadas ($q > 1$) y la superdifusión ($\nu > 1$) con las colas finitas ($q < 1$).

En este marco, se puede proponer una solución tipo q-gaussiana como ansatz para la ecuación de Fokker–Planck. El procedimiento completo de verificación, expuesto en el apéndice C, consiste en insertar esta distribución en la ecuación y comprobar que se satisface formalmente siempre que los coeficientes de normalización y de escala sigan una evolución temporal determinada [17]. De este proceso se obtiene que dichos coeficientes presentan la siguiente forma:

$$Z_q(t) = \left[\frac{\sqrt{\pi}\Gamma\left(\frac{3-q}{2(q-1)}\right)}{\sqrt{q-1}\Gamma\left(\frac{1}{q-1}\right)}\right]^{\frac{2}{3-q}} [(2-q)(3-q)t]^{\frac{1}{3-q}}, \tag{3-20}$$

$$\beta(t) = \left[\frac{\Gamma\left(\frac{1}{q-1}\right)}{\sqrt{\pi}\Gamma\left(\frac{3-q}{2(q-1)}\right)}\right]^{\frac{2(q-1)}{3-q}} \frac{(q-1)^{\frac{q-1}{3-q}}}{[(2-q)(3-q)t]^{\frac{2}{3-q}}}. \tag{3-21}$$

Estas expresiones muestran que la q-gaussiana no solo maximiza S_q, sino que también describe la evolución en el tiempo de un sistema cuya dinámica se rige por una ecuación de difusión no lineal con estructura no extensiva.

3.4. Modelo q-gaussiano de retornos

Los resultados desarrollados en las secciones anteriores encuentran una aplicación directa en el estudio de mercados financieros a través del modelo propuesto por L. Borland [17], en el cual se introduce una generalización del proceso de Wiener con el fin de modelar fluctuaciones estocásticas que presentan colas gruesas. A diferencia del modelo gaussiano tradicional, basado en el movimiento browniano y utilizado en la formulación clásica de precios y retornos financieros, este enfoque incorpora un mecanismo de retroalimentación estadística que vincula directamente la dinámica del proceso con su distribución de probabilidad [42].

3.4.1. Generalización del proceso de Wiener

La formulación parte de una generalización de la ecuación de Ito-Langevin. En su forma más simple, esta describe la evolución temporal de una variable estocástica $\Omega(t)$ sometida a una fuerza determinista $K(\Omega, t)$ y a un ruido blanco gaussiano $\eta(t)$:

$$\frac{d\Omega}{dt} = K(\Omega, t) + g(\Omega, t)\eta(t), \tag{3-22}$$

donde $g(\Omega, t)$ representa la amplitud local del ruido y $\langle \eta(t)\eta(t')\rangle = \delta(t - t')$. Asumiendo que $K(\Omega, t) = 0$ y utilizando la relación $dW = \eta(t)dt$, con $W(t)$ un proceso de Wiener, la ecuación 3-22 se puede expresar como una ecuación diferencial estocástica:

$$d\Omega = g(\Omega, t)dW. \tag{3-23}$$

La clave de la generalización propuesta por Borland radica en establecer un vínculo entre la intensidad del ruido y la distribución de probabilidad del propio proceso. Para ello se propone que:

$$g(\Omega, t)^2 = P(\Omega, t)^{\nu-1}, \tag{3-24}$$

lo que implica que el proceso está afectado por su propia distribución, generando un mecanismo de retroalimentación estadística. Insertando esta relación en la ecuación 3-23, se obtiene una ecuación cuya densidad de probabilidad $P(\Omega, t)$ satisface la ecuación de Fokker–Planck no lineal [42]:

$$\frac{\partial}{\partial t}P(\Omega, t) = \frac{1}{2}\frac{\partial^2}{\partial^2\Omega}[P(\Omega, t)]^{\nu}. \tag{3-25}$$

Ahora, como se vio previamente, si $\nu = 2 - q$ la ecuación 3-25 se convierte directamente en la ecuación 3-19. Así, se define el proceso generalizado de Wiener como:

$$d\Omega = P(\Omega, t)^{(1-q)/2}dW, \tag{3-26}$$

que, por construcción, evoluciona con una distribución de probabilidad de tipo q-gaussiana.

3.4.2. Aplicación al modelo de retornos

Una vez definido este proceso, se toma el modelo para retornos financieros basado en el movimiento browniano geométrico y se sustituye el ruido gaussiano por el proceso Ω. Así, el retorno r en un tiempo t medido en intervalos de tamaño T, se modela como [17]:

$$dr_t(T) = \sigma(t)d\Omega_T, \tag{3-27}$$

donde $\sigma(t)$, de manera análoga al modelo gaussiano, representa la volatilidad instantánea. Dado que Ω_T sigue una distribución q-gaussiana como resultado de la ecuación de Fokker–Planck no lineal, se tiene:

$$P_q(\Omega, T) = \frac{[1 - \beta(T)(1 - q)\Omega^2]_+^{1/(1-q)}}{Z_q(T)}, \tag{3-28}$$

con $Z_q(T)$ y $\beta(T)$ los coeficientes mostrados en las ecuaciones 3-20 y 3-21. Ahora, asumiendo que la volatilidad varía mucho más lentamente que Ω_T, se puede considerar $\sigma(t)$ como

constante durante el intervalo T. Esto permite reescribir el retorno como $r_t(T) = \sigma(t)\Omega_T$. Por cambio de variable y renormalización, la densidad para los retornos 3-28 se obtiene como:

$$P_q(r_t(T)) = \frac{1}{\sigma(t)Z_q(T)} \left[1 - (1-q)\frac{r_t(T)^2}{(3-q)\ \sigma(t)^2\sigma_q(T)^2}\right]_+^{1/(1-q)}, \tag{3-29}$$

donde $\sigma_q(T)$ es un parámetro auxiliar definido a partir de $\beta(T)$, tal que:

$$\sigma_q(T) = \left[\sqrt{\pi(\lambda-1)}\frac{\Gamma\left(\frac{\lambda-1}{2}\right)}{\Gamma\left(\frac{\lambda}{2}\right)}\right]^{\frac{1}{\lambda-1}} \left[\frac{(\lambda-2)}{\lambda}T\right]^{\frac{\lambda}{2(\lambda-1)}}, \quad \text{con } \lambda = \frac{2}{q-1}. \tag{3-30}$$

Esta expresión final proporciona una descripción explícita de la función de densidad de probabilidad de los retornos financieros, incorporando de manera natural el efecto de colas pesadas y permitiendo un ajuste flexible mediante el parámetro q.

4. Dinámica de agentes y comportamiento gregario

4.1. Modelos basados en agentes en econofísica

La modelación basada en agentes ha cobrado una importancia creciente en economía y física social como una estrategia alternativa para describir sistemas compuestos por muchos elementos heterogéneos que interactúan de forma local. Frente al paradigma tradicional de equilibrio, los modelos de agentes permiten una representación más realista de la complejidad de los sistemas. En lugar de imponer resultados agregados, estos enfoques buscan explicar cómo los comportamientos colectivos surgen como consecuencia de reglas simples de decisión individual.

Estos modelos ofrecen varias ventajas fundamentales para el estudio de fenómenos económicos. En primer lugar, permiten incorporar de forma natural la heterogeneidad entre los individuos, lo que resulta esencial para describir sistemas donde las diferencias de información son relevantes [43]. En segundo lugar, permiten modelar interacciones locales, ya sean de cooperación, imitación o competencia, que son difíciles de representar en modelos tradicionales [16, 21, 22]. Finalmente, estos modelos permiten observar dinámicas que no presuponen equilibrio, sino que permiten el estudio de comportamientos fuera del mismo a través de la aparición de estructuras colectivas.

A grandes rasgos, los modelos basados en agentes pueden clasificarse en dos enfoques complementarios. Por un lado, existen aquellos que no parten de una ecuación diferencial explícita para describir la evolución del sistema, sino que se basan en simulaciones de múltiples agentes autónomos que interactúan siguiendo reglas predefinidas. Por otro lado, algunos modelos permiten derivar, a partir de dichas reglas, una descripción continua o estocástica que conecta con los métodos analíticos desarrollados en la física estadística.

4.1.1. Modelos emergentes sin ecuaciones diferenciales explícitas

Este enfoque se construye a partir de un conjunto de agentes, unas condiciones iniciales y un conjunto de reglas de interacción definidas de manera discreta. La evolución del sistema se realiza mediante simulaciones iterativas y los comportamientos colectivos se analizan a partir de las propiedades estadísticas del conjunto de trayectorias. Lo distintivo de estos modelos es que no cuentan con una dinámica continua formulada explícitamente, sino que esta surge como una propiedad emergente del conjunto de reglas.

Modelos de este tipo han sido utilizados en diversos contextos económicos, como la distribución de riqueza, los procesos de intercambio o la formación de precios [21, 22]. En el caso de los modelos de intercambio económico inspirados en sistemas de partículas,

las reglas locales de conservación o ahorro determinan las distribuciones estacionarias de riqueza, logrando reproducir fenómenos relevantes. Aunque estos modelos carezcan de una formulación analítica directa, sus resultados han permitido caracterizar procesos complejos a través de simulaciones eficientes y análisis de patrones colectivos.

4.1.2. Modelos con dinámica estocástica explícita

En contraste, algunos modelos permiten una descripción formal de la evolución del sistema mediante ecuaciones diferenciales estocásticas. Estas ecuaciones se deducen a partir de las reglas de interacción entre los agentes y permiten describir la evolución temporal de variables agregadas como la fracción de agentes en determinado estado, la intensidad de una preferencia o la variación de un precio. Este enfoque permite aplicar herramientas del cálculo estocástico, como las ecuaciones de Langevin o de Fokker–Planck, que fueron presentadas previamente.

Una formulación de este tipo será central en los análisis posteriores. El modelo de Kirman [23], basado en decisiones individuales con influencia social, se puede describir mediante una dinámica de transición entre estados que da lugar a ecuaciones diferenciales estocásticas efectivas. A través de esta representación, es posible analizar propiedades estadísticas del sistema, como su distribución estacionaria, su comportamiento en el tiempo largo o la sensibilidad a los parámetros del modelo. En economía financiera también se han utilizado enfoques similares para construir modelos donde variables como el precio o la volatilidad emergen del comportamiento de grupos heterogéneos de agentes, como fundamentalistas y especuladores [4, 16, 24, 25]. Bajo ciertas condiciones, estas dinámicas pueden reducirse a ecuaciones estocásticas que describen adecuadamente propiedades observadas en los datos.

4.2. Modelo gregario de Kirman

El comportamiento colectivo en sistemas compuestos por múltiples agentes ha sido objeto de estudio tanto en ciencias sociales como en disciplinas naturales. En particular, situaciones en las que individuos idénticos o similares deben elegir entre un número reducido de opciones pueden dar lugar a distribuciones altamente asimétricas, incluso cuando no existen diferencias objetivas entre dichas alternativas. Este tipo de fenómenos plantea preguntas fundamentales sobre la manera en que las decisiones individuales se ven afectadas por la interacción social, la imitación o la simple observación del comportamiento de otros. Lejos de ser una particularidad teórica, estos patrones emergen en diversos contextos, naciendo así una necesidad por lograr una descripción adecuada de estos escenarios.

Una contribución clave en este sentido es el modelo propuesto por Alan Kirman [23], quien construyó un marco estocástico simple para capturar el fenómeno de la "gregariedad" o comportamiento de tipo rebaño. Su motivación inicial provino de observaciones empíricas realizadas en colonias de hormigas, pero su análisis rápidamente encontró analogías significativas con situaciones humanas, especialmente en contextos económicos. El

modelo de Kirman no solo ofrece una explicación alternativa a la existencia de distribuciones colectivas desequilibradas, sino que además permite describir las transiciones espontáneas entre estados agregados opuestos, sin necesidad de introducir perturbaciones exógenas ni múltiples equilibrios deterministas.

4.2.1. Motivación

La formulación del modelo parte de una serie de experimentos realizados por los entomólogos Jean-Louis Deneubourg y Jacques Pasteels [44], quienes observaron que al ofrecer a una colonia de hormigas dos fuentes de alimento idénticas (igualmente accesibles y constantemente renovadas), la mayoría de los individuos se concentraba en una sola de ellas. Al cabo de cierto tiempo, la mayoría podía redirigirse espontáneamente hacia la otra fuente, generando oscilaciones entre dos configuraciones colectivas igualmente posibles pero desequilibradas. Este comportamiento, claramente no atribuible a diferencias en la calidad de las opciones, fue interpretado como el resultado de un proceso de reclutamiento entre los individuos de la colonia.

Kirman observó que fenómenos análogos también se presentan en contextos humanos. Por ejemplo, en la elección entre dos restaurantes prácticamente idénticos, se suele observar que la mayoría de los comensales tiende a concentrarse en uno solo de ellos, incluso si ello implica hacer fila, mientras que el otro permanece casi vacío. Este tipo de comportamiento sugiere que la elección individual no depende exclusivamente de la evaluación objetiva de las alternativas, sino también de la información implícita que proporciona la decisión de otros. De modo similar, en el ámbito financiero se ha propuesto que la existencia de burbujas, cambios abruptos de tendencia o dinámicas altamente volátiles pueden explicarse, al menos en parte, por el contagio de expectativas o por procesos de imitación entre agentes [45, 46]. En todos estos casos, el comportamiento agregado no puede inferirse de manera directa a partir del análisis individual, lo que demuestra la necesidad de modelos capaces de capturar explícitamente las interacciones sociales dentro del sistema.

4.2.2. Formulación estocástica

El modelo propuesto por Kirman, además de capturar de forma cualitativa fenómenos empíricos de comportamiento colectivo, permite ser formulado rigurosamente desde el punto de vista estocástico. A partir de un esquema de agentes que transitan entre dos posibles estados, se puede construir una descripción matemática en términos de una cadena de Markov, y posteriormente, mediante una aproximación de campo continuo, derivar una ecuación diferencial estocástica capaz de describir la evolución del sistema en el límite de gran número de agentes.

Para esto, se considera un sistema de N agentes, cada uno de los cuales puede encontrarse en uno de dos estados posibles. Denotando por X el número de agentes en el primer estado, el número de agentes en el segundo estado es $N - X$. Para describir la evolución de este sistema, Kirman propuso un modelo basado en una cadena de Markov en el que se define la probabilidad de transición entre estados durante un pequeño intervalo

de tiempo Δt. Estas probabilidades están dadas por [24]:

$$p(X \to X+1) = (N-X)(\sigma_1 + hX)\Delta t, \tag{4-1}$$

$$p(X \to X-1) = X[\sigma_2 + h(N-X)]\Delta t. \tag{4-2}$$

En estas expresiones, el parámetro h cuantifica el grado de comportamiento gregario o de imitación en el sistema, mientras que σ_1 y σ_2 representan tasas de transición individuales que no dependen de la interacción con otros agentes (transiciones aleatorias).La forma funcional de estas transiciones puede entenderse considerando que la probabilidad de que un agente transicione a otro estado debe ser proporcional a la cantidad de agentes que actualmente se encuentran en el estado de partida, ya que para que exista una transición desde un estado debe haber al menos un agente en él. Esta probabilidad se multiplica por una tasa total de transición que se compone de dos factores. El primero es la tasa individual aleatoria, que representa una decisión espontánea del agente, mientras que el segundo depende del número de agentes en el estado de destino. Este último factor captura el comportamiento de tipo rebaño, pues al aumentar la cantidad de agentes en el estado contrario, se incrementa la presión social que motiva a realizar el cambio.

Este modelo discreto es adecuado para describir sistemas con un número limitado de agentes, pero en aplicaciones como las que se encuentran en econofísica o finanzas resulta conveniente trabajar con formulaciones continuas que permitan un análisis en el límite de gran número de elementos.

Para obtener una versión continua del modelo, se introduce la variable $x = X/N$, la cual representa la fracción de agentes en el primer estado. Esto permite introducir las siguientes tasas de transición:

$$\pi^+(x) = (1-x)\left[\frac{\sigma_1}{N} + hx\right], \tag{4-3}$$

$$\pi^-(x) = x\left[\frac{\sigma_2}{N} + h(1-x)\right]. \tag{4-4}$$

Con esta notación, las probabilidades de transición adquieren una forma más compacta y conveniente para el tratamiento analítico, ya que se escriben como $p(X \to X \pm 1) = N^2\pi^\pm(x)\Delta t$.

4.2.3. Ecuación diferencial estocástica del sistema

La dinámica de evolución del sistema se puede describir mediante una ecuación maestra que representa el cambio temporal de la densidad de probabilidad $\omega(x,t)$. Esta función da cuenta de la probabilidad de que una fracción x de agentes se encuentre en el primer estado en un tiempo t.

El cambio en $\omega(x,t)$ durante un intervalo infinitesimal de tiempo puede entenderse como el resultado neto de dos procesos. Por un lado, están las transiciones desde estados vecinos hacia el estado x, lo cual incrementa la probabilidad. Por otro, están las transiciones desde x hacia otros estados, lo que reduce dicha probabilidad. En términos

matemáticos, esto se traduce en la siguiente expresión:

$$\frac{\partial \omega(x,t)}{\partial t} = \sum_{i=\pm\frac{1}{N}} [N^2\pi^{\pm}(x-i)\omega(x-i,t) - N^2\pi^{\pm}(x)\omega(x,t)]. \tag{4-5}$$

Cada término en esta ecuación refleja una transición elemental entre estados adyacentes, de modo que al expandirla se obtiene:

$$\frac{\partial \omega(x,t)}{\partial t} = N^2\Bigg\{\pi^+\left(x-\frac{1}{N}\right)\omega\left(x-\frac{1}{N},t\right) + \pi^-\left(x+\frac{1}{N}\right)\omega\left(x+\frac{1}{N},t\right) - [\pi^+(x)+\pi^-(x)]\omega(x,t)\Bigg\}. \tag{4-6}$$

Una forma sencilla de representar esta ecuación es a través del formalismo de paso [47], el cual introduce los siguientes operadores:

$$\begin{aligned} E\,f(x) &= f(x+1/N), \\ E^{-1}\,f(x) &= f(x-1/N), \end{aligned} \tag{4-7}$$

con lo cual la ecuación maestra se expresa como:

$$\frac{\partial \omega(x,t)}{\partial t} = N^2\Bigg\{(E^{-1}-1)[\pi^+(x)\omega(x,t)] + (E-1)[\pi^-(x)\omega(x,t)]\Bigg\}. \tag{4-8}$$

Ahora, si se hace una expansión en series de Taylor de los operadores E y E^{-1} hasta segundo orden:

$$E\,f(x) = f(x+1/N) \approx f(x) + \frac{1}{N}f'(x) + \frac{1}{2N^2}f''(x), \tag{4-9}$$

$$E^{-1}\,f(x) = f(x-1/N) \approx f(x) - \frac{1}{N}f'(x) + \frac{1}{2N^2}f''(x). \tag{4-10}$$

Sustituyendo en 4-8:

$$\frac{\partial \omega(x,t)}{\partial t} = N^2\Bigg\{\left(-\frac{1}{N}\frac{\partial}{\partial x} + \frac{1}{2N^2}\frac{\partial^2}{\partial x^2}\right)[\pi^+(x)\omega(x,t)] + \left(\frac{1}{N}\frac{\partial}{\partial x} + \frac{1}{2N^2}\frac{\partial^2}{\partial x^2}\right)[\pi^-(x)\omega(x,t)]\Bigg\}. \tag{4-11}$$

Agrupando términos, se llega a:

$$\frac{\partial \omega(x,t)}{\partial t} = N\frac{\partial}{\partial x}[(\pi^- - \pi^+)\omega(x,t)] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[(\pi^- + \pi^+)\omega(x,t)]. \tag{4-12}$$

Ahora, definiendo convenientemente las siguientes funciones de x:

$$A(x) = N(\pi^+ - \pi^-) = \sigma_1(1-x) - \sigma_2 x, \tag{4-13}$$

$$B(x) = \pi^+ + \pi^- = 2hx(1-x) + \frac{\sigma_1}{N}(1-x) + \frac{\sigma_2}{N}x \approx 2hx(1-x), \tag{4-14}$$

donde la aproximación final se justifica en el límite de $N \to \infty$. Así, la ecuación 4-12 toma la forma canónica de una ecuación de Fokker-Planck:

$$\frac{\partial \omega(x,t)}{\partial t} = -\frac{\partial}{\partial x}[A(x)\omega(x,t)] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[B(x)\omega(x,t)]. \tag{4-15}$$

Como es habitual en la teoría de procesos estocásticos, la ecuación de Fokker–Planck obtenida puede asociarse a una ecuación diferencial estocástica de tipo Langevin. Su deducción rigurosa se presenta en el apéndice D, pero su forma general se expresa como:

$$dx(t) = A(x,t)\,dt + \sqrt{B(x,t)}\,dW(t), \tag{4-16}$$

donde dW representa un proceso de Wiener. Sustituyendo las expresiones 4-13 y 4-14 se llega a:

$$dx(t) = [\sigma_1(1-x) - \sigma_2 x]\,dt + \sqrt{2hx(1-x)}\,dW(t), \tag{4-17}$$

lo que proporciona una descripción dinámica del sistema a nivel mesoscópico, integrando tanto los efectos de las decisiones individuales como las influencias colectivas debidas al comportamiento gregario.

4.3. Extensión a un modelo de tres estados para agentes financieros

El modelo original de Kirman fue concebido para describir dinámicas de decisión entre dos opciones, lo cual resulta adecuado en una amplia gama de situaciones. Sin embargo, al abordar fenómenos financieros más complejos, se vuelve necesario considerar estructuras con más de dos tipos de comportamiento. Una extensión natural es el caso de tres clases de agentes, donde se introduce una división entre actores fundamentalistas y dos tipos de especuladores: chartistas optimistas y chartistas pesimistas [16].

4.3.1. Estados del sistema y transiciones

Para el esquema planteado, los fundamentalistas se caracterizan por operar con base en el valor intrínseco del activo financiero. Su objetivo es comprar cuando el precio de

mercado está por debajo del valor fundamental y vender cuando está por encima. Por el contrario, los chartistas toman decisiones en función de su percepción de la dinámica futura del mercado, sin recurrir a fundamentos objetivos. Dentro de este grupo se distinguen dos subtipos. Los optimistas adoptan estrategias de compra especulativa, anticipando subidas de precio, mientras que los pesimistas actúan como vendedores anticipando caídas.

En un sistema conformado por N agentes, se define el número de agentes en cada uno de los posibles estados mediante las variables N_i donde $i \in \{f, c, o, p\}$ representa respectivamente a fundamentalistas, todos los chartistas, chartistas optimistas y chartistas pesimistas. También se define la fracción de cada tipo de agente mediante:

$$n_f = \frac{N_f}{N}, \quad n_c = \frac{N_c}{N}, \quad n_o = \frac{N_o}{N}, \quad n_p = \frac{N_p}{N}. \tag{4-18}$$

Los agentes evolucionan transicionando entre estos estados. La figura 4-1 muestra un esquema de todos los tipos de agentes del sistema y las posibles transiciones entre estos, junto con la distinción entre transiciones espontáneas y de tipo gregario.

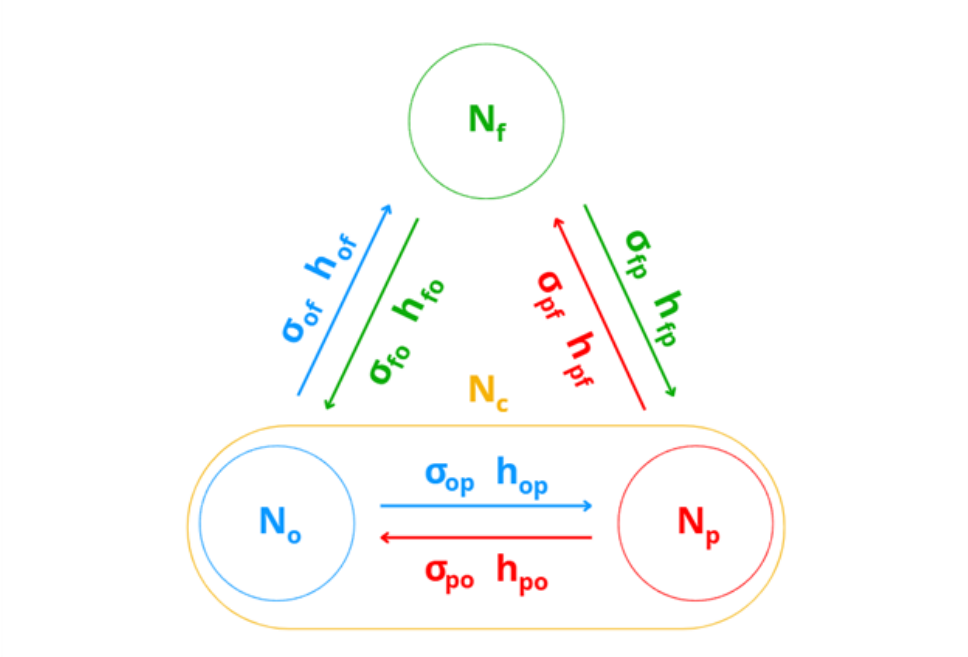

Figura 4-1.: Esquema de los estados posibles y las transiciones entre tipos de agentes en el modelo extendido de tres estados. Las transiciones pueden ser espontáneas (tasa σ_{ij}) o inducidas por comportamiento gregario (tasa h_{ij}).

Para reducir la complejidad del modelo sin perder realismo, se adoptan varias suposiciones sobre las tasas de transición. Las transiciones espontáneas se describen mediante tasas σ_{ij}, y las de tipo imitativo mediante coeficientes h_{ij}. Se hacen las siguientes simplificaciones:

- Las tasas espontáneas entre optimistas y pesimistas se agrupan bajo una sola constante:

$$\sigma_{op} = \sigma_{po} = \sigma_{cc}. \tag{4-19}$$

- Las tasas de transición entre fundamentalistas y chartistas se simplifican de la siguiente manera:

$$\sigma_{fp} = \sigma_{fo} = \sigma_{fc}/2, \quad \sigma_{pf} = \sigma_{of} = \sigma_{cf}. \tag{4-20}$$

- Para las tasas de comportamiento gregario se supone simetría:

$$h_{fp} = h_{pf} = h_{fo} = h_{of} = h. \tag{4-21}$$

- Se introduce el parámetro $H \gg 1$ para reflejar que las transiciones entre tipos de chartistas son mucho más frecuentes que aquellas entre chartistas y fundamentalistas, de modo que:

$$h_{op} = h_{po} = Hh, \quad \sigma_{cc} \gg \sigma_{cf}, \sigma_{fc}. \tag{4-22}$$

4.3.2. Evolución estocástica de los tres estados

Ahora, para realizar una descripción estocástica de este sistema no se puede simplemente utilizar el modelo de Kirman, ya que este modelo está planteado para dos estados. Sin embargo, lo que sí se puede hacer es obtener dos ecuaciones diferenciales estocásticas que delimiten la evolución de los agentes. Para esto se impone la restricción de conservación:

$$n_f + n_o + n_p = 1. \tag{4-23}$$

Agrupando inicialmente a los chartistas en un solo grupo, es posible emplear la misma estructura de tasas de transición del modelo de Kirman para describir el intercambio entre fundamentalistas y chartistas. Las tasas quedan expresadas como:

$$\pi_{cf}(n_f) = (1 - n_f)\left[\frac{\sigma_{cf}}{N} + hn_f\right], \tag{4-24}$$

$$\pi_{fc}(n_f) = n_f\left[\frac{\sigma_{fc}}{N} + h(1 - n_f)\right]. \tag{4-25}$$

De acuerdo con el procedimiento ya presentado en secciones anteriores, estas tasas conducen a una ecuación diferencial estocástica (EDE) para la evolución temporal de n_f:

$$dn_f = [(1 - n_f)\sigma_{cf} - n_f\sigma_{fc}]\, dt + \sqrt{2hn_f(1 - n_f)}\, dW_f. \tag{4-26}$$

Esta ecuación no define enteramente el sistema, ya que se englobaron a los chartistas en un solo grupo. Para desagregar a los chartistas en optimistas y pesimistas, se utiliza nuevamente la relación de conservación 4-23. Esto permite que las tasas de transición entre estos subgrupos puedan expresarse como:

$$\pi_{op}(n_p) = (1 - n_f - n_p)\left[\frac{\sigma_{cc}}{N} + Hhn_p\right], \tag{4-27}$$

$$\pi_{po}(n_p) = n_p\left[\frac{\sigma_{cc}}{N} + Hh(1 - n_f - n_p)\right]. \tag{4-28}$$

Nótese que este caso es distinto a la descripción que se hizo para n_f, ya que las transiciones entre optimistas y pesimistas también dependen de la cantidad de fundamentalistas que hay, por eso aparece el término n_f en ambas tasas de transición. Esto refleja que a mayor proporción de fundamentalistas, menor es la disponibilidad de agentes chartistas para cambiar entre subtipos. Similarmente al caso anterior, estas tasas conducen a la siguiente ecuación diferencial estocástica para n_p:

$$dn_p = (1 - n_f - 2n_p)\sigma_{cc}\,dt + \sqrt{2Hhn_p(1 - n_f - n_p)}\,dW_p. \tag{4-29}$$

Las ecuaciones 4-26 y 4-29 conforman un sistema acoplado de EDEs que describe completamente la evolución de los estados en los que se encuentran los agentes. Sin embargo, resolver este sistema puede ser complicado, por lo que se introduce una variable auxiliar que simplifica la dinámica de los chartistas:

$$\xi(t) = \frac{n_o(t) - n_p(t)}{n_o(t) + n_p(t)}, \tag{4-30}$$

la cual representa el sesgo neto de opinión dentro del conjunto de agentes chartistas. Al reexpresar la ecuación 4-29 en función de ξ, se obtiene una ecuación independiente que describe su evolución temporal:

$$d\xi = -2\sigma_{cc}\xi\,dt + \sqrt{2Hh(1 - \xi^2)}\,dW_\xi. \tag{4-31}$$

De esta forma, las ecuaciones 4-26 y 4-31 constituyen un sistema desacoplado que captura de manera eficiente la dinámica del modelo gregario con tres tipos de agentes.

5. Integración del enfoque estocástico y el modelo de agentes

5.1. Volatilidad como puente entre dinámica macroscópica y microscópica

En los capítulos anteriores se abordaron dos niveles complementarios de modelado para describir los fenómenos financieros. Por un lado, se plantearon modelos estocásticos de retornos y, por el otro, se desarrolló un modelo gregario de agentes heterogéneos, en el cual se explicita el comportamiento de distintos tipos de participantes.

Partiendo de esta distinción entre enfoques, Kononovicius y Gontis [16] propusieron un modelo híbrido que permite integrar ambos niveles a través de la volatilidad como variable compartida. En los modelos estocásticos de retornos, esta cantidad aparece como parámetro clave, reflejando la intensidad de las fluctuaciones. En el enfoque propuesto, la volatilidad se redefine como una función explícita del comportamiento colectivo de los agentes, lo cual permite establecer un puente entre la dinámica macroscópica de los precios y las interacciones microscópicas que emergen del modelo gregario de tres estados desarrollado previamente.

Para contextualizar esta integración, conviene recordar las dos formas principales en las que se modelaron previamente los retornos financieros. En primer lugar, se consideró una dinámica basada en un proceso de Wiener, con una volatilidad local $\sigma(t)$, que da lugar a una distribución con la siguiente forma:

$$r_t(T) = \left(\mu(t) - \frac{1}{2}\sigma(t)^2\right) T + \sigma(t) W_T. \tag{5-1}$$

En segundo lugar, se introdujo una generalización de este esquema a través de un proceso estocástico impulsado por una variable aleatoria Ω_T con distribución q-gaussiana, lo que permite capturar colas más pesadas en la distribución de retornos:

$$r_t(T) = \sigma(t)\, \Omega_T. \tag{5-2}$$

Ambos modelos reflejan un enfoque macroscópico, donde la volatilidad $\sigma(t)$ actúa como una magnitud externa que controla la amplitud de las fluctuaciones, sin una justificación explícita de su origen o evolución interna.

5.1.1. Planteamiento funcional de la volatilidad

La clave para unir ambos enfoques reside en dotar a la volatilidad $\sigma(t)$ de una estructura interna que refleje las tensiones del sistema a nivel de agentes. Para ello, se introduce el concepto de log-precio:

$$p(t) = \ln \frac{P(t)}{P_f(t)}, \tag{5-3}$$

donde $P(t)$ es el precio real del activo y $P_f(t)$ su precio fundamental. Esta magnitud representa la desviación relativa entre el precio observado y el que los agentes fundamentalistas consideran correcto. Cuando ambos precios coinciden, el log-precio se anula, y se asume que el sistema se encuentra en equilibrio.

La volatilidad se modela entonces como una función lineal del valor absoluto de esta desviación:

$$\sigma(t) = b(1 + a|p(t)|), \tag{5-4}$$

donde b establece una escala base de fluctuación (asociada al ruido macroscópico del mercado) y a cuantifica el impacto del alejamiento del precio respecto al valor fundamental. Este planteamiento permite distinguir dos fuentes de variabilidad. Por un lado, una componente exógena e ineludible, incluso cuando el mercado está en equilibrio; y por otro, una componente endógena que depende del comportamiento colectivo de los agentes.

5.1.2. Modelado del log-precio mediante excesos de demanda

Para justificar que el log-precio puede considerarse una variable de origen microscópico, se lo modela directamente desde el punto de vista del sistema de agentes. La idea central es que los precios se ajustan en función del exceso de demanda, es decir, si la demanda supera a la oferta, el precio tiende a aumentar, y si ocurre lo contrario, el precio disminuye.

Este principio puede aplicarse diferenciando el comportamiento de los distintos tipos de agentes. En el caso de los fundamentalistas, se supone que conocen el valor fundamental del activo, y por tanto compran cuando el precio real está por debajo de este valor y venden en caso contrario. Esta dinámica puede modelarse mediante el siguiente exceso de demanda:

$$ED_f = N_f(t) \ln \frac{P_f(t)}{P(t)} = -N_f(t)\, p(t). \tag{5-5}$$

En el caso de los chartistas, los optimistas se comportan como compradores y los pesimistas como vendedores, independientemente del valor fundamental. Su exceso de demanda puede representarse de forma proporcional como:

$$ED_f = c[N_o(t) - N_p(t)], \tag{5-6}$$

donde c es un coeficiente que ajusta la escala de su impacto. Sumando ambas contribuciones, el exceso total de demanda queda dado por:

$$ED = ED_f + ED_c = c[N_o(t) - N_p(t)] - N_f(t)\,p(t). \tag{5-7}$$

Para cerrar el sistema, se introduce un escenario Walrasiano, es decir, se plantea que el modelo cumple con las características de un mercado justo en el cual el precio se regula continuamente para equilibrar la oferta y la demanda. De acá se supone una proporcionalidad entre el cambio del precio en el tiempo y el exceso de demanda. Para este caso, como las desviaciones son moderadas, es correcto trabajar directamente con el log-precio:

$$\frac{dp(t)}{dt} = \alpha\, ED, \tag{5-8}$$

donde α es un parámetro de sensibilidad. Sustituyendo la expresión 5-7 y reescribiendo en función de las fracciones $n_i = N_i/N$, se obtiene:

$$\frac{1}{\alpha N}\frac{dp(t)}{dt} = c(n_o - n_p) - n_f\, p(t). \tag{5-9}$$

En el límite cuando $N \to \infty$, la parte de izquierda tenderá a cero, con lo cual, el log precio queda expresado como:

$$p(t) = c\frac{n_o - n_p}{n_f}, \tag{5-10}$$

o expresándolo en función de la variable ξ definida en la ecuación 4-30:

$$p(t) = c\frac{1 - n_f}{n_f}\xi. \tag{5-11}$$

Sustituyendo esta expresión en la ecuación 5-4, y absorbiendo el parámetro c en la constante a, se obtiene finalmente:

$$\sigma(t) = b\left(1 + a\left|\frac{n_o - n_p}{n_f}\right|\right) = b\left(1 + a\left|\frac{1 - n_f}{n_f}\xi\right|\right). \tag{5-12}$$

Esta relación muestra de forma explícita cómo la volatilidad del modelo macroscópico emerge de la estructura interna del sistema de agentes. En particular, refleja que las tensiones generadas por el desequilibrio entre optimistas y pesimistas se amplifican cuando la proporción de fundamentalistas (actores que estabilizan el mercado) disminuye. Así, el modelo logra conectar de manera coherente la dinámica de precios con el comportamiento colectivo de los participantes del mercado.

5.2. Variabilidad de la tasa de eventos τ

En el modelo de agentes gregarios planteado anteriormente, se asumía que los cambios de estrategia por parte de los agentes ocurrían con una frecuencia constante. No obstante, esta suposición contradice la dinámica observada en los mercados financieros reales, en los que se alternan períodos de alta volatilidad con otros de relativa calma. Esta variabilidad sugiere que la frecuencia con la que los agentes revisan y modifican sus decisiones no es uniforme, sino que responde al estado general del mercado. Para capturar este fenómeno, Kononovicius y Gontis [16, 25] propusieron introducir una variable de escala temporal τ, la cual modula la intensidad de las transiciones entre estados dentro del modelo de tres agentes previamente expuesto.

Esta nueva formulación considera que los agentes chartistas (optimistas y pesimistas) son susceptibles a las condiciones del mercado y, por tanto, ajustan más frecuentemente su estrategia en contextos volátiles. En contraste, los fundamentalistas se asumen más estables en sus decisiones, por lo que su comportamiento permanece inalterado frente a estas variaciones. La introducción de la variable τ permite modificar directamente la escala temporal de las ecuaciones diferenciales estocásticas asociadas a las fracciones de agentes en los distintos estados, de la siguiente forma:

$$dn_f = \left[\frac{(1-n_f)\sigma_{cf}}{\tau} - n_f\sigma_{fc}\right] dt + \sqrt{\frac{2hn_f(1-n_f)}{\tau}}\, dW_f, \tag{5-13}$$

$$d\xi = -\frac{2\sigma_{cc}\xi}{\tau}\, dt + \sqrt{\frac{2Hh(1-\xi^2)}{\tau}}\, dW_\xi. \tag{5-14}$$

Tal como se aprecia, una disminución en τ implica una aceleración de las dinámicas estocásticas, en donde los agentes chartistas reaccionan con mayor rapidez y el sistema se vuelve más sensible a perturbaciones. En cambio, un incremento en τ indica que las transiciones entre estados se ralentizan, reproduciendo situaciones de menor actividad o calma en los mercados.

Una cuestión clave es cómo modelar adecuadamente esta variable τ. Para ello, se recurre a observaciones empíricas que evidencian una relación de tipo ley de potencias entre el volumen de transacciones V y el retorno absoluto r de los activos financieros [48], del estilo:

$$V(r) \sim r^\alpha, \quad \text{con } \alpha \approx 2. \tag{5-15}$$

Esta relación indica que, en promedio, los retornos más grandes suelen coincidir con volúmenes de intercambio más altos. Como la tasa de transacciones está inversamente relacionada con el tiempo de espera entre eventos, es razonable suponer que esta tasa crece con el retorno, conduciendo a una relación como:

$$\frac{1}{\tau} \propto r^\alpha. \tag{5-16}$$

En este modelo, el retorno absoluto no se introduce directamente, sino que se utiliza el log-precio $p(t)$ que se definió con anterioridad. Esta relación permite interpretar el log-precio como una medida proporcional a las desviaciones especulativas del precio respecto al valor fundamental. Así, se propone el siguiente modelo para la tasa de eventos:

$$\frac{1}{\tau(n_f, \xi)} = (1 + a|p(t)|)^\alpha = \left(1 + a\left|\frac{1 - n_f}{n_f}\xi\right|\right)^\alpha, \tag{5-17}$$

donde a es el mismo parámetro que se mostró en la definición de la volatilidad, y α corresponde al exponente de la ley de potencias, típicamente cercano a 2. Esta expresión vincula la escala temporal del modelo con el comportamiento colectivo de los agentes, ya que cuando las fracciones de optimistas y pesimistas están desbalanceadas o la proporción de fundamentalistas es baja, el valor de $|p(t)|$ se incrementa, lo que a su vez disminuye τ y acelera la dinámica del sistema.

En resumen, la introducción de una tasa de eventos variable permite que la frecuencia de interacción entre los agentes se adapte dinámicamente a las condiciones del mercado. Con ello, se dota al modelo de mayor flexibilidad y realismo, incorporando un vínculo explícito entre el comportamiento colectivo y la escala temporal de las fluctuaciones del sistema financiero.

5.3. Resolución numérica: método de Euler-Maruyama

Las ecuaciones diferenciales estocásticas que surgen del modelo gregario de tres agentes con dependencia dinámica del tiempo τ presentan una estructura complicada de resolver, lo cual impide obtener soluciones analíticas exactas. Por esta razón, resulta necesario implementar un método de integración numérica adecuado. Uno de los métodos más utilizados para aproximar soluciones de ecuaciones diferenciales estocásticas (EDEs) de tipo Itô es el método de Euler–Maruyama [26], una extensión natural del esquema de Euler para ecuaciones deterministas. Este método, aunque simple, es suficiente para capturar las principales propiedades estocásticas del sistema, especialmente cuando se emplea con un paso de integración lo suficientemente pequeño y adaptativo.

Antes de aplicar el esquema de discretización, se realiza un cambio de variables con el objetivo de simplificar la representación de los parámetros y facilitar el análisis de la dinámica. En particular, se define:

$$\varepsilon_{cf} = \frac{\sigma_{cf}}{h}, \quad \varepsilon_{fc} = \frac{\sigma_{fc}}{h}, \quad \varepsilon_{cc} = \frac{\sigma_{cc}}{Hh}. \tag{5-18}$$

Con estas sustituciones, las ecuaciones diferenciales estocásticas que gobiernan la evolución de las fracciones de agentes se reescriben como:

$$dn_f = \left[\frac{(1 - n_f)h\,\varepsilon_{cf}}{\tau(n_f, \xi)} - n_f h\,\varepsilon_{fc}\right] dt + \sqrt{\frac{2hn_f(1 - n_f)}{\tau(n_f, \xi)}}\, dW_f, \tag{5-19}$$

$$d\xi = -\frac{2Hh\,\varepsilon_{cc}\,\xi}{\tau(n_f,\xi)}\,dt + \sqrt{\frac{2Hh(1-\xi^2)}{\tau(n_f,\xi)}}\,dW_\xi. \tag{5-20}$$

Aplicando el método de Euler–Maruyama con paso de tiempo variable a las ecuaciones (5-19) y (5-20), se obtiene el siguiente esquema de evolución discreta:

$$n_{f,i+1} = n_{f,i} + \left[\frac{(1-n_{f,i})h\,\varepsilon_{cf}}{\tau(n_{f,i},\xi_i)} - n_{f,i}h\,\varepsilon_{fc}\right]\Delta t_i + \sqrt{\frac{2hn_{f,i}(1-n_{f,i})}{\tau(n_{f,i},\xi_i)}\Delta t_i}\,\zeta_{1,i} \tag{5-21}$$

$$\xi_{i+1} = \xi_i - \frac{2Hh\,\varepsilon_{cc}\,\xi_i}{\tau(n_{f,i},\xi_i)}\,\Delta t_i + \sqrt{\frac{2Hh(1-\xi_i^2)}{\tau(n_{f,i},\xi_i)}\Delta t_i}\,\zeta_{2,i} \tag{5-22}$$

donde $\zeta_{1,i}$ y $\zeta_{2,i}$ son variables aleatorias independientes, extraídas de una distribución normal estándar $\mathcal{N}(0,1)$, que representan la componente estocástica de cada iteración.

Una característica fundamental del esquema anterior es el uso de un paso de tiempo variable Δt_i, que permite ajustar dinámicamente la resolución temporal del sistema en función del estado actual. Esta elección busca optimizar la eficiencia computacional y mantener la precisión de la integración, especialmente en presencia de rápidas fluctuaciones inducidas por la dinámica del modelo. El paso de tiempo se define como:

$$\Delta t_i = \frac{\kappa^2\tau\left(x_i,\xi_i\right)}{h\left(1+\varepsilon_{cf}+\varepsilon_{fc}+H\left(1+2\varepsilon_{cc}\right)\right)}, \tag{5-23}$$

donde κ es un parámetro que ajusta la precisión numérica. Así, la evolución temporal se actualizaría mediante:

$$t_{i+1} = t_i + \Delta t_i. \tag{5-24}$$

La forma funcional de Δt_i se justifica como una estrategia para escalar adecuadamente la frecuencia de muestreo según la intensidad de las interacciones entre agentes. En particular, al dividir el tiempo característico τ por una combinación ponderada de todos los parámetros del sistema, se asegura que el paso de integración sea lo suficientemente pequeño para captar los efectos dominantes de la dinámica sin introducir errores de integración significativos.

5.4. Ruido externo gaussiano y q-gaussiano

Una vez establecida la conexión entre la dinámica macroscópica de los retornos y la estructura microscópica de los agentes, es posible definir explícitamente cómo esta interacción se refleja en las distribuciones de probabilidad de los retornos financieros. En particular, se analizarán los casos vistos previamente en los que el ruido externo que gobierna la evolución estocástica de los retornos obedece una estadística gaussiana o q-gaussiana, incorporando la dependencia de la volatilidad respecto a la composición del sistema de agentes.

5.4.1. Caso gaussiano

En la sección 2.5 se derivó la forma funcional de la distribución gaussiana para los retornos a corto plazo, la cual se expresa como:

$$P(r_t(T)) = \frac{1}{\sqrt{2\pi\sigma(t)^2 T}} \exp\left\{-\frac{[r_t(T) - \mu(t)T + \frac{1}{2}\sigma(t)^2 T]^2}{2\sigma(t)^2 T}\right\}. \tag{5-25}$$

Sin embargo, al integrar la influencia del modelo de agentes mediante una volatilidad dinámica, es razonable suponer que el término de deriva $(\mu - \frac{1}{2}\sigma^2)T$ puede omitirse. Esta simplificación se justifica en tanto que las fluctuaciones inducidas por los agentes (y no una tendencia sistemática en el precio) dominan la dinámica en las escalas temporales estudiadas. De esta forma, la distribución se reduce a:

$$P(r_t(T)) = \frac{1}{\sqrt{2\pi\sigma(t)^2 T}} \exp\left\{-\frac{r_t(T)^2}{2\sigma(t)^2 T}\right\}. \tag{5-26}$$

Dado que la volatilidad ha sido expresada como función de las fracciones de agentes en la ecuación 5-12:

$$\sigma(t) = b\left(1 + a\left|\frac{1 - n_f}{n_f}\xi\right|\right), \tag{5-27}$$

la función de densidad de probabilidad se reescribe como:

$$P(r_t(T)) = \frac{1}{\sqrt{2\pi b\left(1 + a\left|\frac{1-n_f}{n_f}\xi\right|\right)^2 T}} \exp\left\{-\frac{r_t(T)^2}{2b\left(1 + a\left|\frac{1-n_f}{n_f}\xi\right|\right)^2 T}\right\}. \tag{5-28}$$

De forma equivalente, esta expresión puede ser escrita como una transformación de una variable aleatoria normal estándar:

$$r_t(T) = b\left(1 + a\left|\frac{1 - n_f}{n_f}\xi\right|\right)\sqrt{T}\,\mathcal{N}(0,1), \tag{5-29}$$

donde $\mathcal{N}(0,1)$ representa una variable aleatoria con distribución normal estándar. Esta formulación resulta especialmente útil en la implementación numérica, ya que permite simular los retornos generando directamente una secuencia de valores normales estándar, y modulando la dispersión mediante la volatilidad dependiente del estado del sistema.

5.4.2. Caso q-gaussiano

Por otro lado, en la sección 3.4 se presentó el modelo de retornos con ruido externo q-gaussiano. La correspondiente función de densidad de probabilidad es:

$$P_q(r_t(T)) = \frac{1}{\sigma(t)Z_q(T)}\left[1 - (1-q)\frac{r_t(T)^2}{(3-q)\ \sigma(t)^2\sigma_q(T)^2}\right]_+^{1/(1-q)}, \tag{5-30}$$

donde $Z_q(T)$ y $\sigma_q(T)$ son los coeficientes presentados en las ecuaciones 3-20 y 3-30 respectivamente. De modo análogo al caso gaussiano, esta distribución puede ser interpretada como una transformación de una variable aleatoria q-gaussiana "estándar":

$$r_t(T) = \sigma(t)\sigma_q(T)\,\mathcal{N}_q(0,1) = b\left(1 + a\left|\frac{1-n_f}{n_f}\xi\right|\right)\sigma_q(T)\,\mathcal{N}_q(0,1), \tag{5-31}$$

donde $\mathcal{N}_q(0,1)$ obedece la distribución:

$$P_q(u) = \frac{1}{Z_q(T)}\left[1 - (1-q)\frac{u^2}{(3-q)}\right]_+^{1/(1-q)}. \tag{5-32}$$

Las expresiones finales 5-29 y 5-31 constituyen una síntesis precisa de cómo la volatilidad endógena, determinada por las dinámicas del modelo de agentes, se integra en los modelos macroscópicos de retornos. En ambos casos, se obtiene una estructura que permite simular la evolución de precios financieros con una base estadística sólida y que incorpora explícitamente los efectos colectivos de los agentes sobre la amplitud de las fluctuaciones.

6. Metodología y resultados

6.1. Metodología

6.1.1. Simulación con ruido gaussiano

Para implementar numéricamente el modelo gaussiano con ruido microscópico, se generaron conjuntos de números aleatorios distribuidos según una gaussiana estándar $\mathcal{N}(0,1)$, con tamaños comprendidos entre $1{,}6 \times 10^5$ y $1{,}3 \times 10^6$. Cada valor generado representa un retorno por minuto dentro de la simulación. Esta generación se realizó utilizando la función numpy.random.normal del paquete NumPy en Python, garantizando independencia entre los valores y una correcta implementación de la distribución estándar.

Simultáneamente, se implementó el modelo gregario de agentes para obtener una evolución temporal de la volatilidad, que se incorpora de forma dinámica en la generación de retornos. Las condiciones iniciales para el modelo de agentes se fijaron en $n_{f,0} = 0,6$ y $\xi_0 = 0$. No obstante, dado que la simulación se realiza sobre períodos temporales largos, estas condiciones iniciales resultan poco relevantes en la estadística final del sistema.

Los parámetros del modelo fueron escogidos en concordancia con los valores propuestos por Kononovicius y Gontis en [16], con el objetivo de reproducir un escenario en el cual los comportamientos especulativos dominan el mercado y los agentes fundamentalistas son, en comparación, una minoría frágil. Los valores utilizados fueron: $\varepsilon_{cf} = 0,1$, $\varepsilon_{fc} = 3$, $\varepsilon_{cc} = 3$, $H = 300$, $h = 10^{-8}$ s^{-1}, $a = 0{,}5$, $b = 1$ y $\alpha = 2$.

La simulación de la dinámica de los agentes permitió obtener la evolución temporal de las variables $n_f(t)$ y $\xi(t)$, de las cuales depende directamente la volatilidad. Sin embargo, la integración del sistema se realiza utilizando el método de Euler-Maruyama con paso de tiempo adaptativo Δt, definido por la ecuación (5-23), lo que implica que los puntos temporales no están uniformemente distribuidos. Para asociar una volatilidad a cada minuto exacto, fue necesario construir una trayectoria regular a partir de estos datos. El procedimiento consistió en que, para cada instante múltiplo de un minuto dentro de la simulación, se identificaron los dos valores de tiempo irregular que lo encierran, es decir, el punto inmediatamente anterior y el punto inmediatamente posterior. Luego, se realizó una interpolación lineal entre los valores de n_f y ξ correspondientes a esos dos tiempos, obteniendo así una estimación precisa de estas variables en el instante regular deseado. Este procedimiento permitió reconstruir una serie con resolución temporal de un minuto, a partir de la dinámica generada con paso adaptativo.

Una vez obtenida una trayectoria temporal de n_f y ξ con resolución de un minuto, se calculó la volatilidad en cada instante utilizando la ecuación (5-12). Finalmente, los valores de esta volatilidad fueron multiplicados por los números aleatorios previamente generados, lo cual permitió construir la serie de retornos conforme a la ecuación 5-29 reproduciendo

así numéricamente el modelo gaussiano con retroalimentación microscópica.

6.1.2. Simulación con ruido q-gaussiano

El procedimiento de simulación para el modelo con ruido q-gaussiano sigue una estructura análoga a la utilizada en el caso gaussiano. No obstante, en este caso la generación de los números aleatorios obedece a una distribución distinta, cuya forma funcional se encuentra definida por la ecuación 5-32. Esta función de densidad de probabilidad describe una distribución q-gaussiana "estándar", correspondiente al valor de $q = 1,5$, que equivale a fijar el parámetro $\lambda = 4$.

Para construir una serie de números aleatorios que sigan dicha distribución, se emplea el método de la función inversa de la función acumulativa (CDF). Inicialmente, se generan números aleatorios distribuidos según una distribución uniforme $\mathcal{U}(0,1)$, del mismo modo que en la simulación previa. Luego, cada uno de estos valores se transforma mediante la función inversa de la CDF de la distribución q-gaussiana "estándar". De esta manera, se obtiene un conjunto de variables aleatorias que siguen la distribución deseada, sin necesidad de emplear métodos de aceptación y rechazo ni otras técnicas más complejas.

Una vez generado este conjunto de variables aleatorias, se multiplican por la volatilidad correspondiente a cada instante de tiempo, calculada exactamente del mismo modo que en la simulación gaussiana. En particular, se reutiliza la misma evolución para las variables del modelo de agentes n_f y ξ, así como la interpolación temporal utilizada para obtener valores por minuto de dichas variables.

Finalmente, al combinar estos números q-gaussianos con la volatilidad variable, se construye una serie temporal de retornos que representa una realización del modelo con retroalimentación microscópica, bajo el supuesto de que el ruido que impulsa las fluctuaciones del sistema es de carácter q-gaussiano. Esto permite reproducir numéricamente la ecuación 5-31, cerrando así la implementación del modelo híbrido para este caso.

6.1.3. Datos empíricos y tratamiento de la información

Con el objetivo de comparar los resultados obtenidos en las simulaciones con datos reales, se trabajó con dos conjuntos distintos de información empírica. El primero corresponde a retornos financieros por minuto de acciones pertenecientes a distintas bolsas de valores; el segundo, a retornos diarios de activos macroeconómicos seleccionados.

Para el caso de las acciones bursátiles, se recopilaron datos de tres mercados distintos. De la Bolsa de Nueva York (NYSE) se consideraron las acciones de General Motors (GM), Altria Group (MO) y AT&T (T), en un periodo comprendido entre enero de 2005 y marzo de 2007. De la Bolsa de Varsovia (Warsaw Stock Exchange) se seleccionaron las acciones TPSA y KGHM, desde noviembre del año 2000 hasta enero de 2014, y la acción PZU, desde mayo de 2010 hasta enero de 2014. Finalmente, de la Bolsa de Lituania (Nasdaq Vilnius), se utilizaron datos de las acciones APG1L, IVL1L, PTR1L, SAB1L y TEO1L, en el periodo comprendido entre mayo de 2005 y diciembre de 2013. En todos estos casos, se trabajó con retornos por minuto y fueron tomados del anexo proporcionado por Kononovicius y Gontis en [16].

Para obtener una función de densidad de probabilidad representativa de cada mercado, se construyó la función de densidad para cada acción por separado y, posteriormente, se promedió la densidad obtenida entre todas las acciones pertenecientes a una misma bolsa. De esta manera, se obtuvo una PDF promedio para cada una de las tres bolsas de valores consideradas: NYSE, Warsaw SE y Nasdaq Vilnius.

El segundo conjunto de datos se consideraron los retornos diarios del valor del petróleo de referencia Brent, así como del tipo de cambio entre el peso colombiano (COP) y el dólar estadounidense (USD). Estos datos cubren el periodo comprendido entre enero de 2010 y enero de 2015. La obtención de los mismos se hizo a través de la plataforma de Investing.com, utilizando una descarga manual.

6.2. Análisis de resultados

Una vez implementado el modelo en su variante gaussiana y q-gaussiana y definidos los distintos escenarios de simulación y análisis empírico, se procede a examinar los resultados obtenidos. Para esto, se deben identificar las principales propiedades emergentes del sistema, compararlas con los datos reales y evaluar la capacidad del modelo para capturar fenómenos característicos de los mercados financieros.

6.2.1. Límites dinámicos en la simulación del modelo

Una de las observaciones más relevantes que emergen del modelo estudiado está relacionada con el comportamiento temporal de la fracción de agentes fundamentalistas, n_f, y sus consecuencias sobre la estabilidad de la dinámica de retornos. Como se ha discutido en secciones anteriores, se espera que el modelo llegue a una estructura en la cual los agentes fundamentalistas constituyan una minoría frente al predominio especulativo de los agentes chartistas. Esto reflejaría una visión conductual de los mercados financieros contemporáneos, donde el comportamiento racional tiende a ser cada vez más marginal frente a dinámicas impulsivas y de corto plazo.

En la Figura 6-1, se ilustra la evolución de la variable n_f en función del tiempo para una simulación en la cual se utilizó una semilla de números aleatorios específica y un tiempo máximo de simulación de $t_{max} = 2 \times 10^5$ minutos. Se observa una tendencia sistemática de decrecimiento en la proporción de fundamentalistas hasta alcanzar, en torno al final del intervalo de simulación, valores cercanos a cero. Esta dinámica es consecuencia directa de la parametrización del modelo, en la cual las tasas de transición favorecen una migración neta de fundamentalistas hacia comportamientos chartistas. Como resultado, el sistema tiende a un estado dominado casi por completo por dinámicas especulativas, eliminando progresivamente el componente racional del mercado.

Este fenómeno impacta directamente la validez y aplicabilidad del modelo. Al considerar que la volatilidad está acoplada a la estructura poblacional de agentes mediante el término $|(1 - n_f)\xi/n_f|$, es evidente que cuando $n_f \to 0$, dicho cociente diverge, llevando a que el log-precio tienda a valores extremos y, en consecuencia, la volatilidad se dispare. Esta divergencia genera un régimen numéricamente inestable en el cual los retornos simulados alcanzan magnitudes poco realistas, afectando la distribución de los resultados.

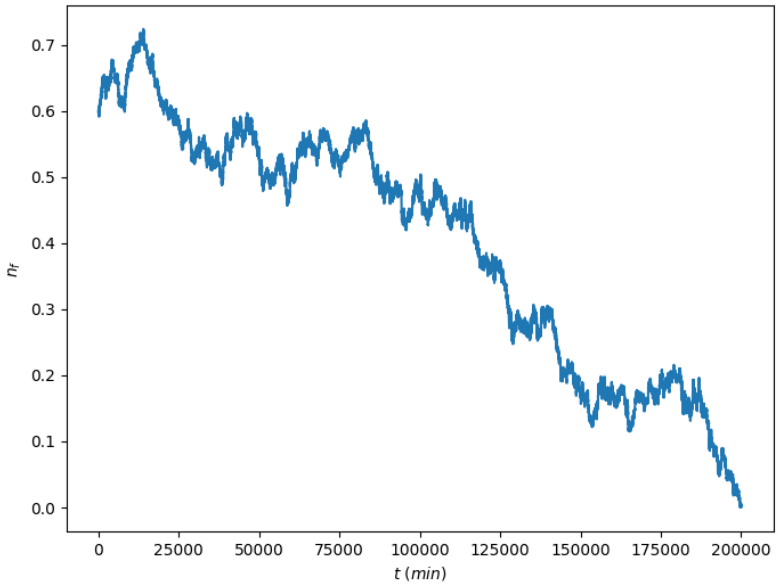

Figura 6-1.: Evolución temporal de la fracción de fundamentalistas n_f para una semilla específica.

Para analizar este efecto con mayor precisión, en la Figura 6-2 se presentan las funciones de densidad de probabilidad del valor absoluto de los retornos, simulados con distintos valores de t_{max}, antes y después de alcanzado el umbral en que n_f se aproxima a cero. En el panel (a), se muestran los resultados para el caso con ruido gaussiano, mientras que en el panel (b) se presentan los correspondientes al ruido q-gaussiano. En ambos casos, puede observarse que, para tiempos de simulación inferiores a aproximadamente 2×10^5 minutos (esto es, antes de la extinción de fundamentalistas), las distribuciones obtenidas son estables y mantienen una forma coherente, con colas que decaen según una misma tendencia y sin presencia de eventos extremos desproporcionados.

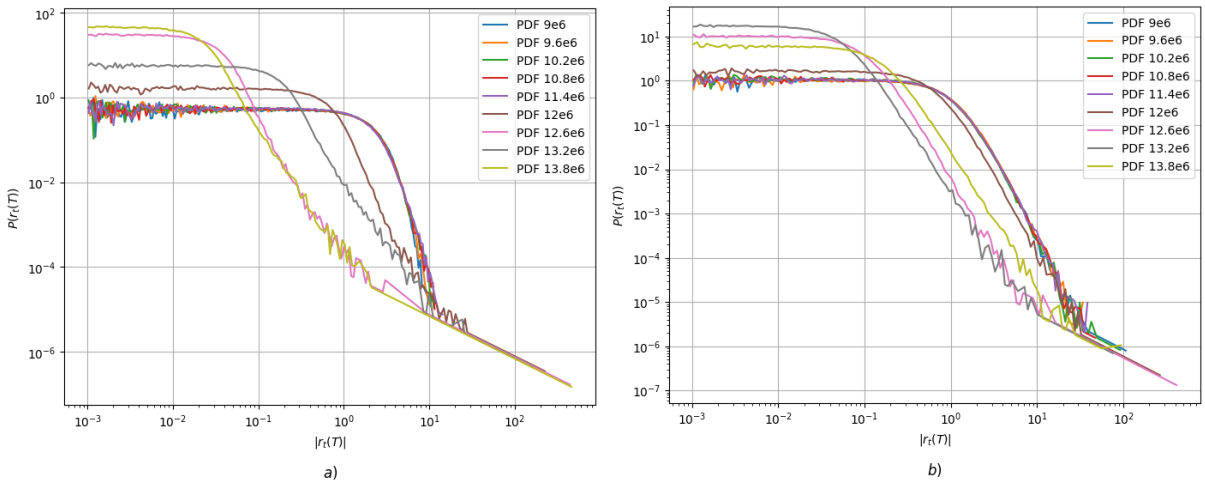

Figura 6-2.: Funciones de densidad de probabilidad del valor absoluto de los retornos $r_t(T)$ para diferentes tiempos de simulación t_{max} con a) retornos generados con ruido gaussiano b) retornos generados con ruido q-gaussiano.

No obstante, a partir de dicho umbral se empieza a evidenciar una clara pérdida de consistencia, en donde las funciones de densidad se desvían significativamente de las anteriores, exhibiendo decaimientos diferentes a la tendencia que se venía presentando y picos desplazados hacia regiones de probabilidad ínfima. Confirmando que se pierde capacidad de representación realista cuando la fracción de agentes racionales se anula, alterando la dinámica del sistema de manera estructural.

Este resultado, además de evidenciar la sensibilidad del sistema ante la desaparición de los agentes racionales, revela que la existencia de un límite temporal natural a su aplicabilidad surge como una característica interna, no como una limitación externa o impuesta arbitrariamente. El modelo, en su propia dinámica, establece hasta qué punto puede sostener un equilibrio estocástico coherente. Más allá de este umbral, las ecuaciones conducen a un régimen en el que la volatilidad se vuelve divergente y la distribución de retornos se aleja radicalmente de la que se observa empíricamente, lo que señala el fin de la validez del modelo bajo su formulación actual.

Esta propiedad puede interpretarse como una ventaja estructural del modelo, ya que su capacidad para autodelimitar el rango de tiempo en el que sus resultados son consistentes lo diferencia de otros enfoques que requieren criterios externos o artificiales para fijar horizontes de simulación. Esta autorregulación se alinea, además, con una visión realista de los mercados, en la que una excesiva homogeneidad en el comportamiento de los agentes (en este caso, la desaparición total del componente racional) lleva a dinámicas inestables o inverosímiles.

Adicionalmente, este resultado abre la posibilidad de investigar mecanismos que, dentro del marco del mismo modelo, introduzcan una forma de reestabilización o retorno parcial de la racionalidad, ya sea mediante perturbaciones externas o condiciones endógenas que favorezcan la reaparición de fundamentalistas.

6.2.2. Comparación con datos de acciones de alta frecuencia

Una vez establecida la viabilidad del modelo dentro de un intervalo de tiempo finito, se procede a evaluar su capacidad para reproducir estadísticamente el comportamiento observado en los datos empíricos de alta frecuencia. Con este fin, se generaron dos conjuntos de series de retornos por minuto a partir del mismo modelo de agentes en el que uno utiliza ruido gaussiano y el otro ruido q-gaussiano. En ambos casos, se empleó una semilla cuidadosamente seleccionada que permitiera simular hasta un tiempo máximo de $T = 1{,}3 \times 10^6$ minutos sin cruzar el umbral crítico a partir del cual los fundamentalistas desaparecen del sistema y la simulación se vuelve inestable. Esta elección garantiza un conjunto de datos simulados suficientemente extenso para realizar comparaciones significativas.

Las figuras 6-3, 6-4 y 6-5 presentan la función de densidad de probabilidad (PDF) del valor absoluto de los retornos por minuto obtenidos con el modelo, contrastados con los datos empíricos provenientes de la Bolsa de Nueva York (NYSE), la Bolsa de Varsovia (WARSAW) y la Bolsa de Lituania (NASDAQ Vilnius), respectivamente. En cada figura, el panel izquierdo (a) corresponde al caso con ruido gaussiano, mientras que el panel derecho (b) muestra los resultados obtenidos con ruido q-gaussiano.

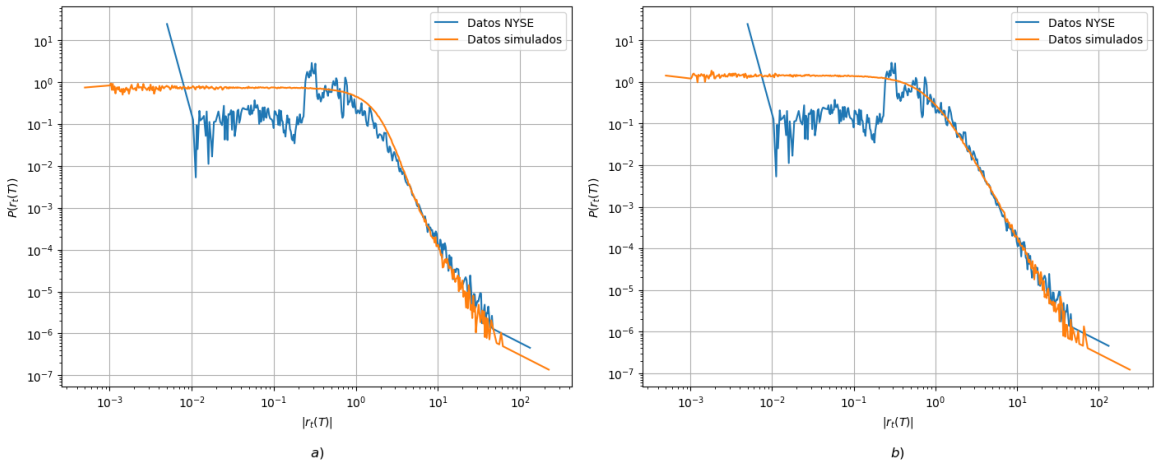

Figura 6-3.: Comparación de la PDF del valor absoluto de los retornos simulados con (a) ruido gaussiano y (b) ruido q-gaussiano, con los datos de NYSE.

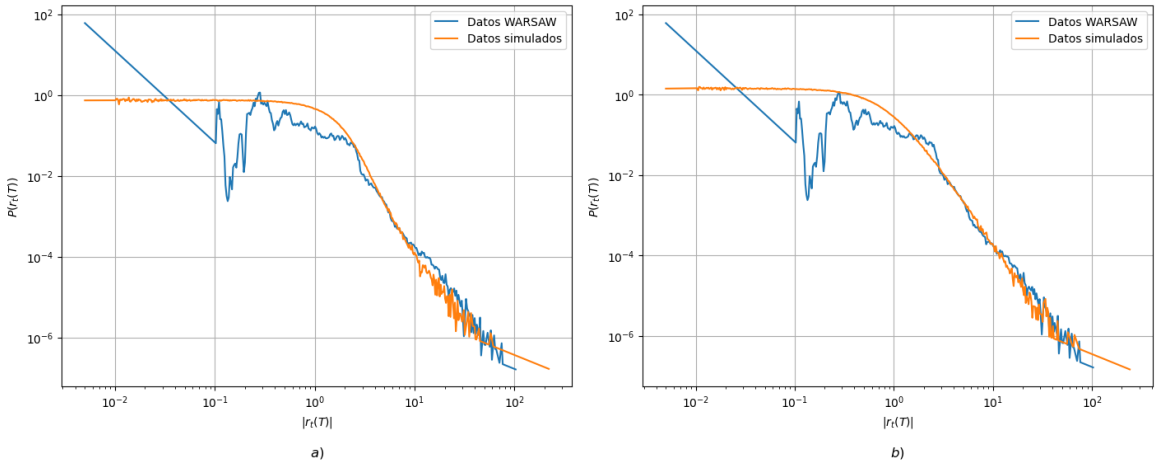

Figura 6-4.: Comparación de la PDF del valor absoluto de los retornos simulados con (a) ruido gaussiano y (b) ruido q-gaussiano, con los datos de Warsaw SE.

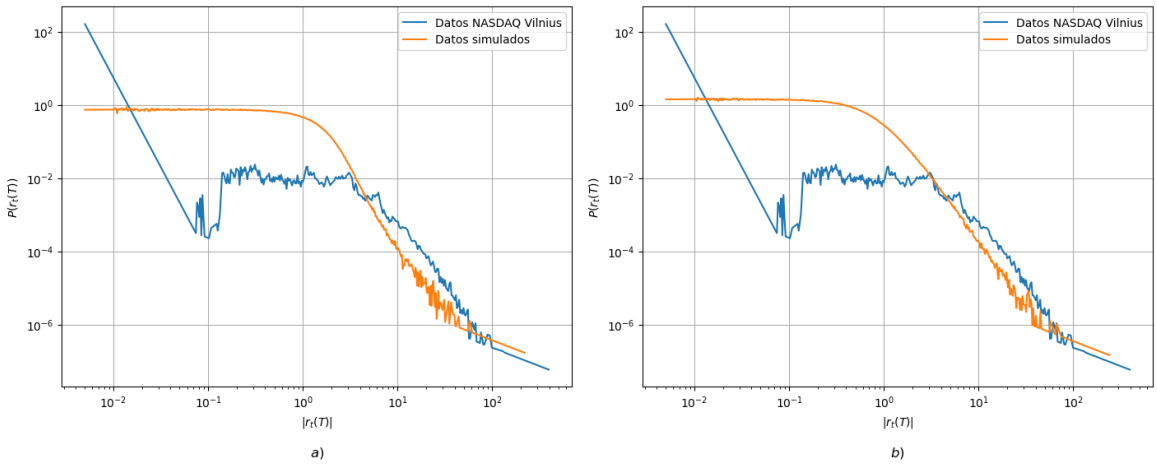

Figura 6-5.: Comparación de la PDF del valor absoluto de los retornos simulados con (a) ruido gaussiano y (b) ruido q-gaussiano, con los datos de Nasdaq Vilnius.

En términos generales, se observa que el modelo con ruido q-gaussiano ofrece una mejor aproximación a los datos empíricos en todos los casos considerados. Las colas de las distribuciones simuladas presentan una caída más lenta y prolongada, en concordancia con la naturaleza pesada de las colas observadas en los datos reales. Este comportamiento es consistente con la hipótesis de que los retornos financieros a alta frecuencia exhiben distribuciones leptocúrticas. La capacidad del modelo q-gaussiano para capturar esta característica sin necesidad de ajustar adicionalmente los parámetros para cada conjunto de datos empíricos constituye una fortaleza notable, sugiriendo una forma de universalidad emergente del mecanismo de retroalimentación introducido entre la dinámica microscópica de los agentes y la dinámica macroscópica de los retornos.

En contraste, aunque el modelo con ruido gaussiano logra aproximarse razonablemente a los datos en las colas, su desempeño es inferior en términos generales, especialmente en la representación del decaimiento como ley de potencias y en la amplitud de las colas. No obstante, incluso en este caso, los resultados son cercanos, lo cual sugiere que parte del comportamiento empírico puede ser capturado únicamente con la modulación de la volatilidad inducida por el modelo de agentes, sin la necesidad de introducir una distribución no gaussiana.

Al examinar los diferentes mercados por separado, se encuentra que para NYSE (Figura 6-3) y Warsaw SE (Figura 6-4), las simulaciones (especialmente las q-gaussianas) presentan una concordancia destacable con los datos empíricos. Esto indica que el modelo estudiado reproduce con éxito la estructura estadística de los retornos en mercados desarrollados o con alta liquidez. En contraste, para el caso de Nasdaq Vilnius (Figura 6-5), la correspondencia es menos precisa. En particular, las colas de la distribución simulada y empírica divergen de manera apreciable, lo que podría deberse a la menor liquidez y profundidad de este mercado. Esta diferencia sugiere que el modelo podría estar mejor adaptado para representar mercados consolidados, mientras que su aplicación en contextos emergentes podría requerir ajustes adicionales.

Un aspecto adicional es el comportamiento cerca del origen ($|r_t| \to 0$), donde se evidencia una discrepancia entre los datos empíricos y las simulaciones, incluso en el caso q-gaussiano. Este fenómeno podría atribuirse a la presencia de ruido de alta frecuencia o a fenómenos propios del mercado, que afectan en mayor medida los retornos pequeños y que no están incorporados explícitamente en el modelo actual. A pesar de ello, la correcta reproducción de las colas, que son las regiones más relevantes para la caracterización del riesgo extremo, respalda la solidez del enfoque estudiado.

6.2.3. Evaluación con distintos activos financieros

Se consideran ahora activos financieros de naturaleza distinta a las acciones, como el precio del petróleo Brent y la tasa de cambio entre el peso colombiano (COP) y el dólar estadounidense (USD), con el fin de evaluar la capacidad del modelo para reproducir sus propiedades estadísticas. Además de explorar esta aplicabilidad a distintos tipos de activos, se busca examinar cómo varía el comportamiento del modelo al modificar la escala temporal de análisis.

Para ello, se implementó un procedimiento de reescalamiento sobre los datos si-

mulados con el fin de construir retornos agregados a diferentes escalas. Dado que las simulaciones se generaron con resolución de un minuto, se construyeron nuevos conjuntos de datos agrupando secuencialmente los retornos por minuto. De esta forma, se consideraron escalas de 10 minutos, 1 hora (60 minutos) y 1 día bursátil (480 minutos), en adición al caso original de 1 minuto. Por ejemplo, para obtener los retornos horarios, se sumaron bloques de 60 retornos consecutivos. Este procedimiento se aplicó tanto para la simulación con ruido gaussiano como para la simulación con ruido q-gaussiano, generando así ocho conjuntos de datos simulados (cuatro escalas para cada tipo de ruido).

Los resultados se presentan en las figuras 6-6 y 6-7, donde se muestran las distribuciones de probabilidad empíricas del valor absoluto de los retornos diarios del petróleo y el dólar junto con las distribuciones simuladas. La figura 6-6 corresponde al caso con ruido gaussiano, y la figura 6-7, al caso con ruido q-gaussiano. En ambas, los subgráficos (a), (b), (c) y (d) representan, respectivamente, los resultados para las escalas de 1 minuto, 10 minutos, 1 hora y 1 día.

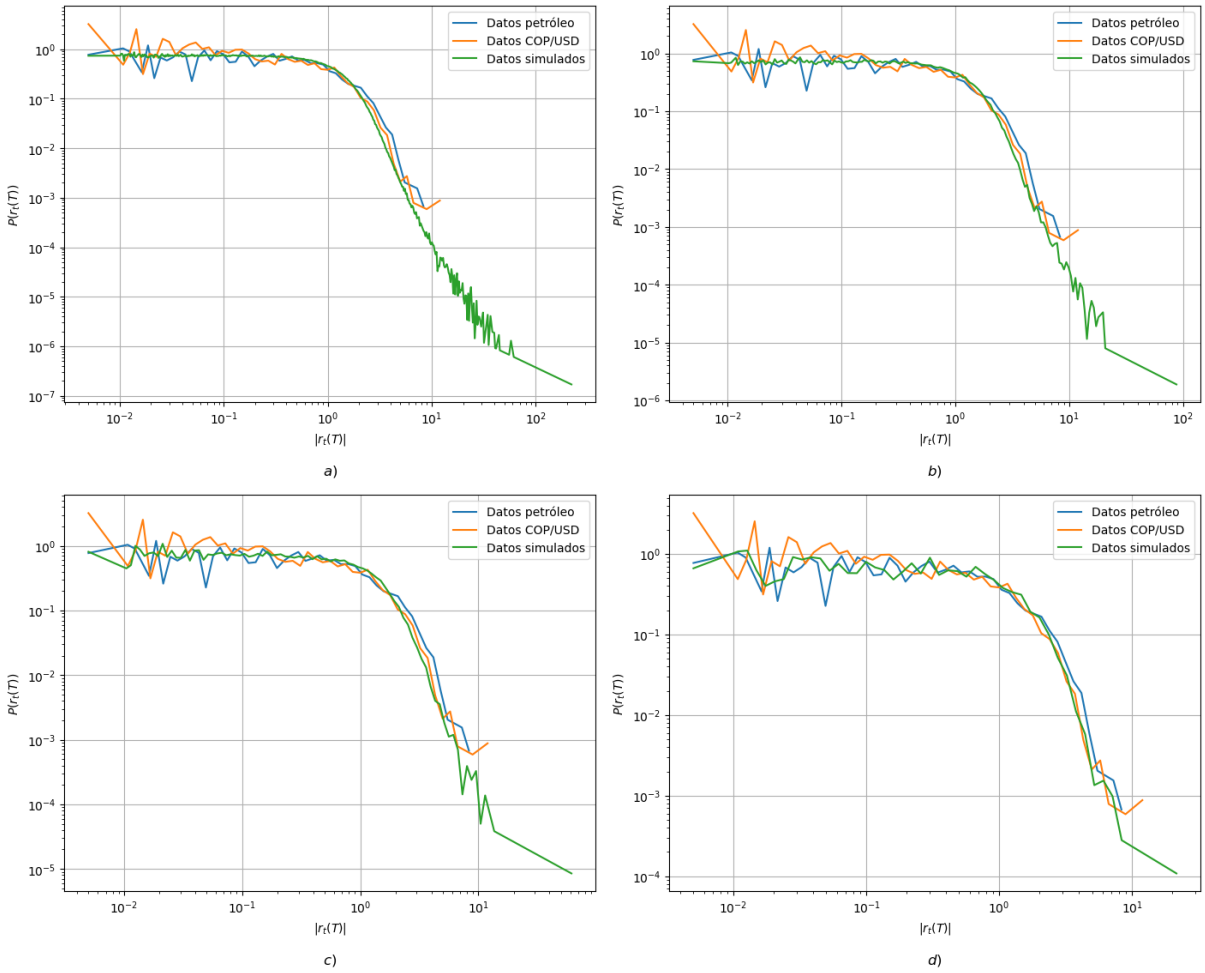

Figura 6-6.: Comparación entre la PDF de los datos empíricos del petróleo y el tipo de cambio COP/USD con la simulada con ruido gaussiano y escala temporal de (a) 1 minuto, (b) 10 minutos, (c) 1 hora, (d) 1 día.

En el caso de la figura 6-6, se observa que las distribuciones simuladas se mantienen notablemente estables al cambiar la escala. Esta invariancia a escala sugiere que el

modelo con ruido gaussiano presenta una estructura interna autosimilar, lo que resulta atractivo desde el punto de vista del modelado financiero. Además, se aprecia una buena concordancia entre las distribuciones simuladas y los datos empíricos, particularmente en la zona central de las distribuciones.

Para cuantificar esta concordancia, se calculó el Error Relativo Medio (ERM) entre las curvas simuladas y empíricas. Los resultados obtenidos para cada escala se muestran en la siguiente tabla:

Escala	ERM Petróleo	ERM COP/USD
1 minuto (a)	0,3514	0,2996
10 minutos (b)	0,3322	0,2928
1 hora (c)	0,3605	0,2849
1 día (d)	0,2729	0,3366

Tabla 6-1.: Error Relativo Medio entre las distribuciones simuladas con ruido gaussiano y las empíricas del petróleo y COP/USD.

Los valores obtenidos muestran una buena estabilidad frente al cambio de escala y, al mismo tiempo, una cercanía suficiente como para afirmar que el modelo con ruido gaussiano reproduce con precisión razonable el comportamiento estadístico de estos activos.

En contraste, la figura 6-7 muestra que, en el caso del ruido q-gaussiano, el modelo presenta ligeras variaciones frente al cambio de escala. La distribución simulada para retornos por minuto difiere significativamente de los datos empíricos, mostrando colas más pesadas. No obstante, a medida que se incrementa la escala temporal, la diferencia se reduce progresivamente y se observa una mayor aproximación entre las curvas. Este comportamiento sugiere que el ruido q-gaussiano, si bien más sensible a la escala, capta mejor las características empíricas de este tipo de activos financieros en escalas amplias, como la diaria.

Los valores correspondientes del Error Relativo Medio se presentan en la siguiente tabla:

Escala	ERM Petróleo	ERM COP/USD
1 minuto (a)	0,8971	0,6021
10 minutos (b)	0,4943	0,3644
1 hora (c)	0,4144	0,3409
1 día (d)	0,3530	0,2820

Tabla 6-2.: Error Relativo Medio entre las distribuciones simuladas con ruido q-gaussiano y las empíricas del petróleo y COP/USD.

Estos resultados muestran una tendencia decreciente en los valores del ERM, reflejando que el modelo con ruido q-gaussiano logra una mejor aproximación conforme se aumenta la escala temporal. Este fenómeno podría estar relacionado con un efecto de agregación, donde las contribuciones de colas pesadas en escalas pequeñas se suavizan y resultan en distribuciones más compatibles con los datos empíricos agregados.

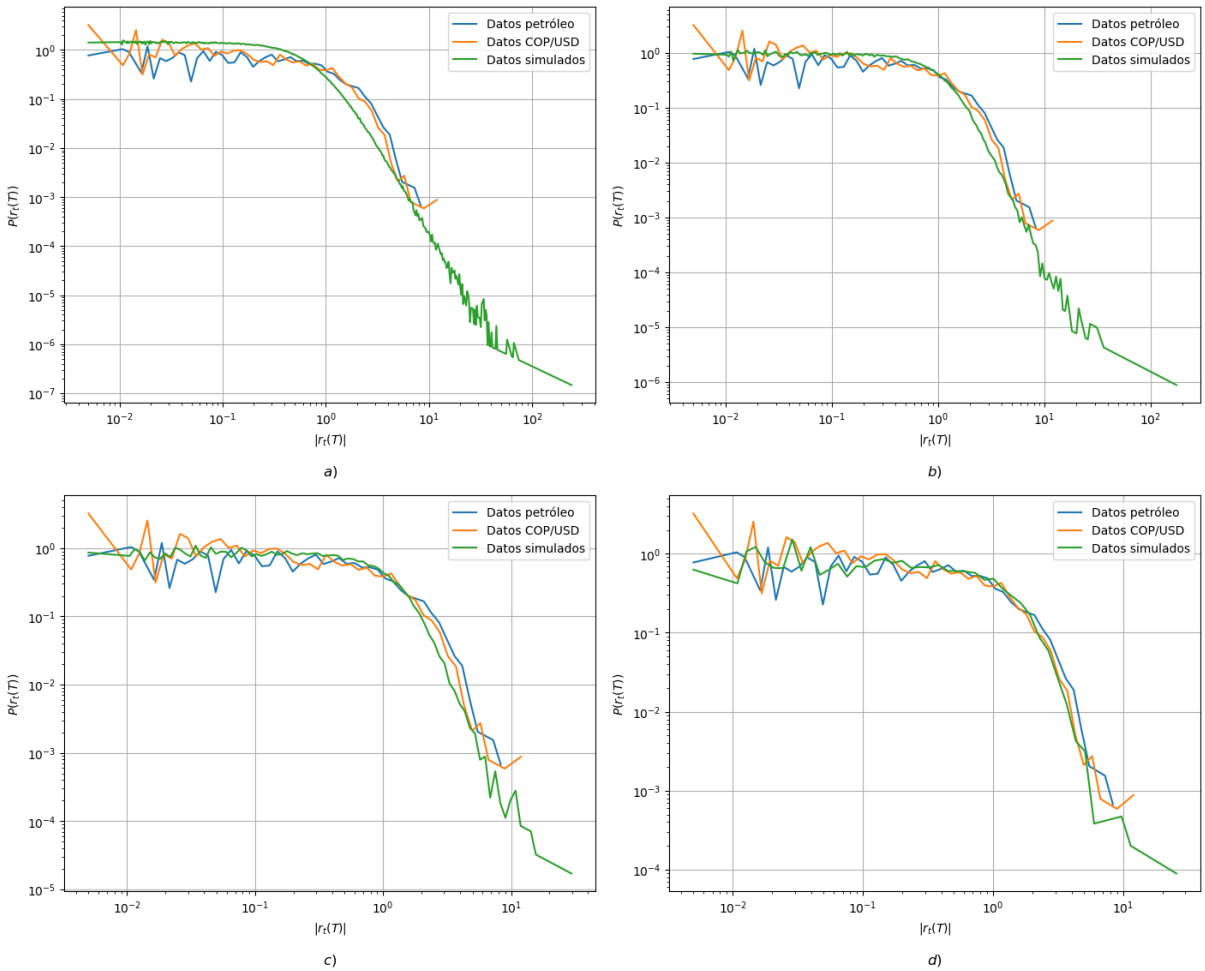

Figura 6-7.: Comparación entre la PDF de los datos empíricos del petróleo y el tipo de cambio COP/USD con la simulada con ruido q-gaussiano y escala temporal de (a) 1 minuto, (b) 10 minutos, (c) 1 hora, (d) 1 día.

En general, lo que arrojó la investigación refuerza la flexibilidad del modelo estudiado. La variante gaussiana exhibe una notable estabilidad estructural y buenos ajustes generales, mientras que la variante q-gaussiana, pese a requerir escalas mayores para lograr un ajuste aceptable, proporciona un mejor modelado de colas pesadas, lo cual es una propiedad empírica ampliamente documentada en activos financieros. La capacidad del modelo para ajustarse razonablemente bien a estos dos activos, sin necesidad de reparametrización específica para cada caso, fortalece su validez como herramienta general de modelado financiero.

7. Conclusiones

El desarrollo de este trabajo comenzó con un tratamiento detallado del enfoque clásico de retornos financieros basado en el movimiento browniano geométrico. A través del uso de herramientas fundamentales del cálculo estocástico, se presentó una deducción rigurosa de la forma funcional que toman los retornos bajo la hipótesis de ruido gaussiano, lo que permitió sentar las bases formales del enfoque estocástico tradicional. Esta estructura fue complementada por un estudio profundo del formalismo de la mecánica estadística no extensiva, el cual proporcionó una vía teórica robusta para justificar la aparición de distribuciones q-gaussianas como generalización natural del modelo tradicional. Este desarrollo teórico también permitió sustentar la aplicabilidad de dichas distribuciones en contextos financieros marcados por la presencia de colas pesadas y estados fuera del equilibrio.

En paralelo a este desarrollo, se abordó con detalle la formulación del modelo de Kirman como base para introducir un componente microscópico en la dinámica de los mercados. Se partió del análisis de las tasas de transición entre estados, se construyó la correspondiente ecuación maestra, y se obtuvo su versión continua a través de una aproximación de tipo Fokker–Planck. Esta deducción permitió comprender cómo, a partir de supuestos simples sobre el comportamiento gregario de los agentes y la existencia de cambios de opinión inducidos socialmente, emerge una dinámica no trivial en la proporción de agentes de distintos tipos. Además, se mostró cómo esta dinámica puede describirse también mediante una ecuación estocástica de tipo Langevin, lo que facilita su integración posterior con la volatilidad del modelo estocástico.

Sobre esta base, se logró establecer una integración coherente entre el enfoque estocástico de los retornos financieros y una dinámica basada en agentes, construida sobre una perspectiva descriptiva de los mercados. Esta articulación entre los niveles macroscópico y microscópico se llevó a cabo mediante una definición funcional de la volatilidad, que permitió traducir el comportamiento colectivo de los agentes en una expresión concreta de las fluctuaciones de precio. El resultado fue un modelo híbrido que no solo reproduce estadísticamente las propiedades empíricas más relevantes de las series financieras, sino que también las vincula a una interpretación dinámica del comportamiento de los participantes del mercado.

Un aspecto particularmente destacable es la capacidad del modelo para replicar las distribuciones de probabilidad observadas en dos bolsas de valores consolidadas y con alta liquidez como lo son la Bolsa de Nueva York (NYSE) y la Bolsa de Varsovia (Warsaw SE). A pesar de que no se realizó una reparametrización específica para cada conjunto de datos empíricos, los retornos simulados a partir del modelo lograron un ajuste considerable con las distribuciones empíricas obtenidas a partir de los datos históricos de acciones en estos mercados. Esta capacidad de adaptación sin ajuste fino de parámetros refuerza la validez general del modelo y su aplicabilidad a distintos entornos financieros. No obstante, al

aplicar el mismo análisis a los datos de la Bolsa de Vilnius, un mercado emergente y de menor liquidez relativa, se observó una disminución en la calidad del ajuste, lo cual sugiere que la capacidad del modelo para capturar las propiedades empíricas de los retornos podría estar condicionada, al menos en parte, por el grado de consolidación del mercado al que se aplique.

La comparación entre los dos tipos de ruido considerados mostró una diferencia significativa en la capacidad del modelo para capturar las colas pesadas características de las distribuciones empíricas de alta frecuencia. En los tres mercados bursátiles estudiados, el modelo con ruido q-gaussiano mostró un ajuste notablemente mejor en las colas de las distribuciones, lo que evidencia su mayor capacidad para describir eventos extremos, típicos de los retornos financieros reales. Sin embargo, al ampliar el análisis a activos financieros de naturaleza distinta a las acciones, como lo son el petróleo Brent y la tasa de cambio entre el peso colombiano y el dólar estadounidense, fue el modelo con ruido gaussiano el que mostró un mejor desempeño. En particular, se evidenció una sorprendente estabilidad en las distribuciones simuladas bajo ruido gaussiano frente a cambios en la escala temporal, lo que permitió obtener una aproximación razonable a los datos empíricos incluso cuando estos se presentaban en una escala diaria. Este comportamiento sugiere que, si bien el modelo con ruido q-gaussiano captura mejor las propiedades estadísticas de alta frecuencia, el enfoque gaussiano posee una mayor robustez frente a la variación temporal, lo cual representa una fortaleza importante de su estructura.

Otro hallazgo relevante es la identificación de un límite natural en el tiempo máximo de simulación impuesto por la dinámica misma del modelo. A medida que transcurre el tiempo, y bajo los parámetros elegidos para reflejar una dominancia progresiva del comportamiento especulativo sobre el racional, la proporción de agentes fundamentalistas disminuye y tiende eventualmente a desaparecer. Este fenómeno produce una divergencia en la volatilidad, que crece de forma descontrolada y genera retornos simulados con valores extremos irreales. Sin embargo, esta característica representa una manifestación del enfoque conductual que inspira al modelo. En efecto, el hecho de que el modelo limite por sí mismo el rango temporal en el cual ofrece resultados válidos es un reflejo de su coherencia interna. La desaparición de los fundamentalistas significa que el sistema ha dejado de ser una mezcla de racionalidad y especulación, para convertirse en una dinámica puramente especulativa fuera del dominio de validez planteado inicialmente. Esta autorregulación del modelo sobre su propio tiempo de simulación puede considerarse una propiedad emergente que fortalece su estructura conceptual.

Finalmente, los resultados obtenidos en el análisis de escalas temporales revelaron una capacidad del modelo para mantener la forma estadística de las distribuciones simuladas bajo diferentes resoluciones temporales. En el caso del ruido gaussiano, las funciones de densidad de probabilidad resultantes permanecieron prácticamente invariantes al cambiar de una escala de minutos a una diaria, y además coincidieron de manera notable con los datos reales del petróleo y del dólar. Esta invariancia sugiere que el modelo reproduce adecuadamente ciertas propiedades universales de los mercados financieros, como la estabilidad de los patrones estadísticos en distintas escalas, al menos para este tipo de activos. Aunque el modelo q-gaussiano mostró un comportamiento menos estable frente al cambio de escala, también presentó una mejora progresiva en el ajuste a medida que

se agregaban retornos en horizontes temporales mayores, lo que sugiere que el efecto del parámetro q podría estar vinculado a fenómenos temporales agregados que aún requieren mayor estudio.

En conjunto, los resultados de este trabajo permiten concluir que el modelo híbrido estudiado no solo ofrece una representación sólida y flexible de los retornos financieros, sino que también proporciona un marco útil para explorar el papel de las decisiones individuales, la estructura del mercado y la escala temporal en la formación de precios. La coherencia teórica, la capacidad de generalización empírica y la riqueza estructural del modelo lo posicionan como una herramienta valiosa en el estudio de fenómenos complejos en finanzas.

A. Apéndice A: Maximización de la entropía de Shannon

En este apéndice se desarrollará la maximización de la entropía de Shannon a través del método de multiplicadores de Lagrange. Para ello se hará uso de la forma continua de esta entropía con $k = 1$ (suposición que no afecta el resultado y facilita el cálculo):

$$S = -\int du\, p(u) \ln p(u). \tag{A-1}$$

Con esto y con las restricciones:

$$\int du\, p(u) = 1, \quad \int du\, (u - u_M) p(u) = 0, \quad \int du\, (u - u_M)^2 p(u) = \sigma^2, \tag{A-2}$$

se define el funcional:

$$\begin{aligned}\mathcal{L}(p) = &-\int du\, p(u) \ln p(u) - \lambda_0 \left(\int du\, p(u) - 1 \right) - \lambda_1 \left(\int du\, (u - u_M) p(u) \right) \\ &- \lambda_2 \left(\int du\, (u - u_M)^2 p(u) - \sigma^2 \right).\end{aligned} \tag{A-3}$$

Ahora, maximizando ($\delta\mathcal{L} = 0$) se obtiene que:

$$\begin{aligned}\delta\mathcal{L} = &-\int du\, \delta p(u) \left(\ln p(u) + 1 \right) - \lambda_0 \int du\, \delta p(u) - \lambda_1 \int du\, (u - u_M) \delta p(u) \\ &- \lambda_2 \int du\, (u - u_M)^2 \delta p(u) = 0.\end{aligned} \tag{A-4}$$

Reorganizando:

$$\delta\mathcal{L} = \int du\, \delta p(u) \left[-\ln p(u) - 1 - \lambda_0 - \lambda_1 (u - u_M) - \lambda_2 (u - u_M)^2 \right] = 0. \tag{A-5}$$

Para que se cumpla esta condición para toda variación $\delta p(u)$ se debe cumplir que el factor dentro del corchete debe anularse, con lo cual:

$$-\ln p(u) - 1 - \lambda_0 - \lambda_1 (u - u_M) - \lambda_2 (u - u_M)^2 = 0. \tag{A-6}$$

Despejando $p(u)$:

$$p(u) = \exp\ \left(-1 - \lambda_0 - \lambda_1(u - u_M) - \lambda_2(u - u_M)^2\right). \tag{A-7}$$

Sin embargo, para que se cumpla la condición de que la distribución resultante esté centrada en u_M no pueden haber términos lineales, con lo cual $\lambda_1 = 0$. Finalmente, reescribiendo $1/Z = \exp\ (-1 - \lambda_0)$ y $\beta = \lambda_2$:

$$p(u) = \frac{1}{Z} e^{-\beta(u-u_M)^2}. \tag{A-8}$$

B. Apéndice B: Maximización de la entropía de Tsallis

De manera similar a como se realizó la maximización de la entropía de Shannon, en este apéndice se realizará la maximización de la entropía de Tsallis haciendo uso del método de multiplicadores de Lagrange. Para este desarrollo se inicia con la forma continua de la entropía de Tsallis:

$$S_q = \frac{1 - \int du\, p(u)^q}{q-1}. \tag{B-1}$$

Junto con esto, se plantean las restricciones:

$$\int du\, p = 1, \quad \int du\, (u - u_M) p^q = 0, \quad \int du\, (u - u_M)^2 p^q = \sigma^2, \tag{B-2}$$

las cuales permiten construir el funcional:

$$\begin{aligned}\mathcal{L}(p) =& \frac{1 - \int du\, p(u)^q}{q-1} - \lambda_0 \left(\int du\, p(u) - 1 \right) - \lambda_1 \left(\int du\, (u - u_M) p(u)^q \right) \\ & - \lambda_2 \left(\int du\, (u - u_M)^2 p(u)^q - \sigma^2 \right).\end{aligned} \tag{B-3}$$

Ahora, maximizando ($\delta\mathcal{L} = 0$) se obtiene que:

$$\begin{aligned}\delta\mathcal{L} =& -\frac{q}{q-1} \int du\, p(u)^{q-1} - \lambda_0 \int du\, \delta p(u) - \lambda_1 \int du\, (u - u_M) q\, p(u)^{q-1} \delta p(u) \\ & - \lambda_2 \int du\, (u - u_M)^2 q\, p(u)^{q-1} \delta p(u) = 0.\end{aligned} \tag{B-4}$$

Reorganizando

$$\int du\, \delta p(u) \left\{ -\frac{q}{q-1}\, p(u)^{q-1} \left[1 + (q-1) \left(\lambda_1 (u - u_M) + \lambda_2 (u - u_M)^2 \right) \right] - \lambda_0 \right\} = 0. \tag{B-5}$$

Para que esta condición se cumpla para cualquier variación $\delta p(u)$, el integrando debe anularse de tal manera que:

$$-\frac{q}{q-1}\,p(u)^{q-1}\left[1+(q-1)\left(\lambda_1(u-u_M)+\lambda_2(u-u_M)^2\right)\right]-\lambda_0=0. \tag{B-6}$$

Ahora, despejando:

$$p(u)^{q-1}=\frac{\lambda_0(1-q)}{q}\left[1+(q-1)\left(\lambda_1(u-u_M)+\lambda_2(u-u_M)^2\right)\right]^{-1}. \tag{B-7}$$

Finalmente, reescribiendo a $Z_q=\frac{q}{\lambda_0(1-q)}$, $\beta=\lambda_2$ y $\lambda_1=0$ para que la distribución pueda estar centrada en u_M:

$$p(u)=\frac{1}{Z_q}\left[1-(1-q)\beta(u-u_M)^2\right]^{\frac{1}{1-q}}. \tag{B-8}$$

C. Apéndice C: Deducción de los coeficientes de la solución de la ecuación de Fokker-Planck no lineal

En este apéndice se presenta la deducción explícita de los coeficientes de la distribución q-gaussiana para garantizar que esta sea solución de la siguiente ecuación de Fokker–Planck no lineal:

$$\frac{\partial}{\partial t}p(x,t) = \frac{1}{2}\frac{\partial^2}{\partial x^2}\left[p(x,t)\right]^{2-q}. \tag{C-1}$$

Se plantea como ansatz la forma general de una distribución q-gaussiana:

$$p(x,t) = \frac{1}{Z_q(t)}\left[1-(1-q)\beta(t)x^2\right]_+^{\frac{1}{1-q}}, \tag{C-2}$$

donde $\beta(t)$ y $Z_q(t)$ son funciones del tiempo que se determinarán a continuación. El subíndice + indica que el soporte de la distribución se restringe al intervalo en el que el argumento es positivo.

C.1. Relación entre Z_q y β por normalización

Para encontrar la forma explícita de las constantes $\beta(t)$ y $Z_q(t)$, se impone primero la condición de normalización sobre la distribución (C-2):

$$\int dx\, p(x,t) = \int dx\, \frac{1}{Z_q(t)}\left[1-(1-q)\beta(t)x^2\right]^{\frac{1}{1-q}} = 1. \tag{C-3}$$

De esta ecuación se deduce que:

$$Z_q(t) = \int dx\, \left[1-(1-q)\beta(t)x^2\right]^{\frac{1}{1-q}}. \tag{C-4}$$

Para resolver esta integral, se realiza el cambio de variable $u = x\sqrt{\beta(t)}$, lo cual conduce a:

$$Z_q(t) = \beta(t)^{-1/2} \int du \, \left[1 - (1-q)u^2\right]^{\frac{1}{1-q}} = \sqrt{\frac{c}{\beta(t)}}, \tag{C-5}$$

donde, siguiendo la notación introducida por Borland [17], se define:

$$\sqrt{c} = \int du \, \left[1 - (1-q)u^2\right]^{\frac{1}{1-q}} . \tag{C-6}$$

C.2. Reemplazo en la ecuación de Fokker–Planck

Para determinar la forma temporal de $Z_q(t)$ y $\beta(t)$, se inserta la expresión (C-2) en ambos lados de la ecuación de Fokker–Planck. Primero se calcula el lado izquierdo (derivada temporal):

$$\frac{\partial p}{\partial t} = -\frac{1}{Z_q^2}\frac{dZ_q}{dt}\left[1 - (1-q)\beta x^2\right]^{\frac{1}{1-q}} - \frac{x^2}{Z_q}\frac{d\beta}{dt}\left[1 - (1-q)\beta x^2\right]^{\frac{q}{1-q}} . \tag{C-7}$$

Ahora, para el lado derecho, se calcula primero la derivada espacial de p^{2-q}:

$$\frac{\partial}{\partial x} p^{2-q} = -\frac{2(2-q)\beta}{Z_q^{2-q}} \, x \left[1 - (1-q)\beta x^2\right]^{\frac{1}{1-q}} , \tag{C-8}$$

y luego su segunda derivada:

$$\frac{1}{2}\frac{\partial^2}{\partial x^2} p^{2-q} = -\frac{(2-q)\beta}{Z_q^{2-q}} \left\{ \left[1 - (1-q)\beta x^2\right]^{\frac{1}{1-q}} - 2\beta x^2 \left[1 - (1-q)\beta x^2\right]^{\frac{q}{1-q}} \right\} . \tag{C-9}$$

C.3. Igualación de términos

Para que se satisfaga la ecuación de Fokker–Planck, deben coincidir los términos con igual dependencia funcional. Al igualar coeficientes se obtiene:

$$\frac{1}{Z_q^2}\frac{dZ_q}{dt} = \frac{(2-q)\beta}{Z_q^{2-q}}, \tag{C-10}$$

$$-\frac{1}{Z_q}\frac{d\beta}{dt} = \frac{2(2-q)\beta^2}{Z_q^{2-q}}. \tag{C-11}$$

Sustituyendo la expresión obtenida en (C-5), estas relaciones se reescriben como:

$$\frac{dZ_q}{dt} = (2-q)\, c\, Z_q^{q-2}, \tag{C-12}$$

$$-\frac{d\beta}{dt} = \frac{2(2-q)}{c^{\frac{1-q}{2}}}\, \beta^{\frac{5-q}{2}}. \tag{C-13}$$

Separando variables e integrando se obtienen las expresiones explícitas:

$$Z_q(t) = [(2-q)(3-q)\,c\,t]^{\frac{1}{3-q}}\,, \tag{C-14}$$

$$\beta(t) = c^{\frac{1-q}{3-q}}\,[(2-q)(3-q)\,t]^{-\frac{2}{3-q}}\,. \tag{C-15}$$

C.4. Cálculo explícito de la constante c

Para obtener el valor exacto de c, se evalúa la integral en (C-6). Aplicando el cambio de variable $\alpha = \sqrt{q-1}, u$, se tiene:

$$\sqrt{c} = \frac{1}{\sqrt{q-1}} \int d\alpha\ \left[1+\alpha^2\right]^{\frac{1}{1-q}}\,. \tag{C-16}$$

Esta integral puede expresarse en términos de la función beta incompleta utilizando la identidad [49]:

$$\int_0^\infty dx\,(1+x^2)^{\nu-1} = \frac{1}{2}B\left(\frac{1}{2},\frac{1}{2}-\nu\right), \tag{C-17}$$

donde, en este caso, $\nu = \frac{2-q}{1-q}$. Por tanto:

$$\sqrt{c} = \frac{1}{\sqrt{q-1}}\,B\left(\frac{1}{2},\frac{3-q}{2(q-1)}\right). \tag{C-18}$$

Usando la relación entre la función beta y la función gamma, $B(x,y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$, se obtiene finalmente:

$$\sqrt{c} = \frac{\sqrt{\pi}\,\Gamma\left(\frac{3-q}{2(q-1)}\right)}{\sqrt{q-1}\,\Gamma\left(\frac{1}{q-1}\right)}. \tag{C-19}$$

Sustituyendo esta expresión en (C-14) y (C-15), se llega a las formas explícitas finales para los coeficientes de la distribución q-gaussiana:

$$Z_q(t) = \left[\frac{\sqrt{\pi}\Gamma\left(\frac{3-q}{2(q-1)}\right)}{\sqrt{q-1}\Gamma\left(\frac{1}{q-1}\right)}\right]^{\frac{2}{3-q}} [(2-q)(3-q)t]^{\frac{1}{3-q}}, \tag{C-20}$$

$$\beta(t) = \left[\frac{\Gamma\left(\frac{1}{q-1}\right)}{\sqrt{\pi}\Gamma\left(\frac{3-q}{2(q-1)}\right)}\right]^{\frac{2(q-1)}{3-q}} \frac{(q-1)^{\frac{q-1}{3-q}}}{[(2-q)(3-q)t]^{\frac{2}{3-q}}}. \tag{C-21}$$

D. Apéndice D: Relación entre una ecuación de Fokker-Palck y una ecuación diferencial estocástica.

En este apéndice se verá la demostración completa de la correspondencia entre una ecuación de Fokker-Planck y una ecuación diferencial estocástica de tipo Langevin. Para esto, se partirá de la siguiente ecuación:

$$dx(t) = a(x,t)\,dt + b(x,t)\,dW(t), \tag{D-1}$$

la cual describe cómo evoluciona la variable estocástica $x(t)$. Acá $a(x,t)$ corresponde con el término de deriva y $b(x,t)$ es el coeficiente de difusión.

Ahora, para el desarrollo de la demostración se considera una función arbitraria $f(x(t))$ y se evalúa su diferencial, el cual corresponde con

$$df = f'(x)\,dx + \frac{1}{2}f''(x)\,dx^2. \tag{D-2}$$

Sustituyendo la ecuación D-1:

$$df = f'(x)[a(x,t)\,dt + b(x,t)\,dW(t)] + \frac{1}{2}f''(x)[b(x,t)]^2 dt. \tag{D-3}$$

Agrupando:

$$df = \left[f'(x)a(x,t) + \frac{1}{2}f''(x)[b(x,t)]^2\right] dt + f'(x)b(x,t)\,dW(t), \tag{D-4}$$

llegando así a la forma diferencial de Ito, la cual describe cómo evoluciona cualquier función $f(x)$.

Posterior a esto, se calcula el cambio en la esperanza de la función $f(x(t))$ [50], es decir:

$$\frac{d}{dt}\langle f(x)\rangle = \left\langle \frac{df(x(t))}{dt} \right\rangle. \tag{D-5}$$

Como el término con dW tiene esperanza cero, solo sobrevive el término determinista:

$$\frac{d}{dt}\langle f(x)\rangle = \left\langle f'(x)a(x,t) + \frac{1}{2}f''(x)[b(x,t)]^2 \right\rangle. \tag{D-6}$$

Asumiendo que la variable aleatoria $x(t)$ tiene una densidad de probabilidad $p(x,t)$, se tiene que:

$$\langle f(x)\rangle = \int f(x)p(x,t)\,dx, \tag{D-7}$$

y, por lo tanto:

$$\frac{d}{dt}\langle f(x)\rangle = \int f(x)\frac{\partial p(x,t)}{\partial t}\,dx. \tag{D-8}$$

Igualando esto con el resultado mostrado en la ecuación D-6:

$$\int f(x)\frac{\partial p(x,t)}{\partial t}\,dx. = \int \left[f'(x)a(x,t) + \frac{1}{2}f''(x)[b(x,t)]^2\right] p(x,t)\,dx. \tag{D-9}$$

Ya con esta expresión, la parte derecha se puede integrar por partes dos veces y al asumir que los términos de frontera se anulan [50], la ecuación D-9 se puede reorganizar como:

$$\int f(x)\frac{\partial p(x,t)}{\partial t}\,dx = \int f(x)\left\{-\frac{\partial}{\partial x}[a(x,t)p(x,t)] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[b^2(x,t)p(x,t)]\right\}\,dx. \tag{D-10}$$

Como esto se cumple para cualquier función $f(x)$, debe cumplirse que:

$$\frac{\partial p(x,t)}{\partial t} = -\frac{\partial}{\partial x}[a(x,t)p(x,t)] + \frac{1}{2}\frac{\partial^2}{\partial x^2}[b^2(x,t)p(x,t)]. \tag{D-11}$$

Llegando así a la ecuación de Fokker-Planck asociada a la ecuación diferencial estocástica propuesta inicialmente.

Bibliografía

[1] Louis Bachelier. *Théorie de la spéculation.* Ph.d. thesis, Université de Paris, 1900. URL `https://gallica.bnf.fr/ark:/12148/bpt6k546196`. Reimpreso en Annales Scientifiques de l'École Normale Supérieure, 3e série, tome 17 (1900), pp. 21–86.

[2] Paul A. Samuelson. Proof that properly anticipated prices fluctuate randomly. *Industrial Management Review*, 6(2):41–49, 1965.

[3] Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952. doi: https://doi.org/10.1111/j.1540-6261.1952.tb01525.x. URL `https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1540-6261.1952.tb01525.x`.

[4] Thomas Lux and Michele Marchesi. Scaling and criticality in a stochastic multi-agent model of a financial market. *Nature*, 397, 08 1998. doi: 10.1038/17290.

[5] Rama Cont. Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236, 2001. doi: 10.1080/713665670.

[6] Zhuanxin Ding, Clive Granger, and Robert Engle. A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1):83–106, 1993. URL `https://EconPapers.repec.org/RePEc:eee:empfin:v:1:y:1993:i:1:p:83-106`.

[7] Vygintas Gontis, Julius Ruseckas, and Aleksejus Kononovicius. A long-range memory stochastic model of the return in financial markets. *Physica A: Statistical Mechanics and its Applications*, 389(1):100–106, 2010. doi: 10.1016/j.physa.2009.09.011.

[8] M. F. M. Osborne. Brownian motion in the stock market. *Operations Research*, 7(2):145–173, 1959. ISSN 0030364X, 15265463. URL `http://www.jstor.org/stable/167153`.

[9] Fischer Black and Myron Scholes. The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3):637–654, 1973. doi: 10.1086/260062.

[10] Robert F. Engle. Autoregressive conditional heteroskedasticity with estimates of the variance of u.k. inflation. *Econometrica*, 50(4):987–1008, 1982.

[11] Tim Bollerslev. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327, 1986.

[12] Richard Baillie, Young-Wook Han, and Robert Myers. Long memory and figarch models for daily and high frequency commodity prices. *Queen Mary, University of London, School of Economics and Finance, Working Papers*, 01 2007.

[13] Laurent Calvet and Adlai Fisher. Multifractality in asset returns: Theory and evidence. *The Review of Economics and Statistics*, 84:381–406, 02 2002. doi: 10.1162/003465302320259420.

[14] Constantino Tsallis. Possible generalization of boltzmann-gibbs statistics. *Journal of Statistical Physics*, 52(1-2):479–487, 1988. doi: 10.1007/BF01016429.

[15] Constantino Tsallis and Dirk Jan Bukman. Anomalous diffusion in the presence of external forces: Exact time-dependent solutions and their thermostatistical basis. *Physical Review E*, 54(3):R2197–R2200, 1996. doi: 10.1103/PhysRevE.54.R2197.

[16] Vygintas Gontis and Aleksejus Kononovicius. Consentaneous agent-based and stochastic model of the financial markets. *PLoS ONE*, 9(7):e102201, 2014. doi: 10.1371/journal.pone.0102201.

[17] Lisa Borland. Option pricing formulas based on a non-gaussian stock price model. *Physical Review Letters*, 89(9):098701, 2002. doi: 10.1103/PhysRevLett.89.098701.

[18] Eric Lutz. Anomalous diffusion and tsallis statistics in an optical lattice. *Phys. Rev. A*, 67:051402, May 2003. doi: 10.1103/PhysRevA.67.051402. URL `https://link.aps.org/doi/10.1103/PhysRevA.67.051402`.

[19] Bin Liu and J. Goree. Superdiffusion and non-gaussian statistics in a driven-dissipative 2d dusty plasma. *Phys. Rev. Lett.*, 100: 055003, Feb 2008. doi: 10.1103/PhysRevLett.100.055003. URL `https://link.aps.org/doi/10.1103/PhysRevLett.100.055003`.

[20] E Samanidou, E Zschischang, D Stauffer, and T Lux. Agent-based models of financial markets. *Reports on Progress in Physics*, 70(3):409–450, February 2007. ISSN 1361-6633. doi: 10.1088/0034-4885/70/3/r03. URL `http://dx.doi.org/10.1088/0034-4885/70/3/R03`.

[21] A. Dragulescu and V.M. Yakovenko. Statistical mechanics of money. *The European Physical Journal B*, 17(4):723–729, October 2000. ISSN 1434-6028. doi: 10.1007/s100510070114. URL `http://dx.doi.org/10.1007/s100510070114`.

[22] A. Chakraborti and B.K. Chakrabarti. Statistical mechanics of money: how saving propensity affects its distribution. *The European Physical Journal B*, 17 (1):167–170, August 2000. ISSN 1434-6028. doi: 10.1007/s100510070173. URL `http://dx.doi.org/10.1007/s100510070173`.

[23] Alan Kirman. Ants, rationality, and recruitment. *The Quarterly Journal of Economics*, 108(1):137–156, 1993. doi: 10.2307/2118404.

[24] Aleksejus Kononovicius and Vygintas Gontis. Agent based reasoning for the nonlinear stochastic models of long-range memory. *Physica A: Statistical Mechanics and its Applications*, 391(4):1309–1314, 2012. doi: 10.1016/j.physa.2011.08.061.

[25] Aleksejus Kononovicius and Vygintas Gontis. Three state herding model of the financial markets. *EPL (Europhysics Letters)*, 101(2):28001, 2013. doi: 10.1209/0295-5075/101/28001.

[26] Peter E. Kloeden and Eckhard Platen. *Numerical Solution of Stochastic Differential Equations*, volume 23 of *Applications of Mathematics*. Springer, Berlin, 3rd edition, 1999. ISBN 978-3-540-54062-5. doi: 10.1007/978-3-642-08107-1.

[27] Claude E. Shannon. A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423, 1948. doi: 10.1002/j.1538-7305.1948.tb01338.x.

[28] E. T. Jaynes. Information theory and statistical mechanics. *Phys. Rev.*, 106:620–630, May 1957. doi: 10.1103/PhysRev.106.620. URL `https://link.aps.org/doi/10.1103/PhysRev.106.620`.

[29] P. D. Dixit. Detecting temperature fluctuations at equilibrium. *arXiv preprint*, 2015. URL `https://arxiv.org/abs/1503.01808`.

[30] Satoshi Tanaka and Yutaka Komeiji. Thermal and quantum fluctuations of harmonic oscillator. *Journal of Physics and Chemistry Research*, 4(3):1–2, 2022. URL `http://dx.doi.org/10.36266/JPCR/151`. Accessed: July 2025.

[31] A. Einstein. Über die von der molekularkinetischen theorie der wärme geforderte bewegung von in ruhenden flüssigkeiten suspendierten teilchen. *Annalen der Physik*, 322(8):549–560, 1905. doi: https://doi.org/10.1002/andp.19053220806. URL `https://onlinelibrary.wiley.com/doi/abs/10.1002/andp.19053220806`.

[32] Jean Perrin. Mouvement brownien et réalité moléculaire. *Annales de Chimie et de Physique*, 18:5–114, 1909.

[33] Norbert Wiener. Differential-space. *Journal of Mathematics and Physics*, 2(1-4):131–174, 1923. doi: https://doi.org/10.1002/sapm192321131. URL `https://onlinelibrary.wiley.com/doi/abs/10.1002/sapm192321131`.

[34] John C. Hull. *Options, Futures and Other Derivatives*. Pearson Education, 10 edition, 2018. ISBN 9780134472089.

[35] Bernt Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. Universitext. Springer, 6 edition, 2003. ISBN 9783540047582. doi: 10.1007/978-3-662-12459-4.

[36] Benoit B. Mandelbrot. The variation of certain speculative prices. *The Journal of Business*, 36(4):394–419, 1963. doi: 10.1086/294632.

[37] G. E. Uhlenbeck and L. S. Ornstein. On the theory of the brownian motion. *Physical Review*, 36:/* original pages */, 1930.

[38] Jean-Philippe Bouchaud and Marc Potters. *Theory of Financial Risk and Derivative Pricing: From Statistical Physics to Risk Management*. Cambridge University Press, 2 edition, 2003. ISBN 9780521819164. doi: 10.1017/CBO9780511753893.

[39] Constantino Tsallis. *Introduction to Nonextensive Statistical Mechanics: Approaching a Complex World*. Springer, New York, NY, 2009. ISBN 9780387853581. doi: 10.1007/978-0-387-85359-8.

[40] R. Silva, A. R. Plastino, and J. A. S. Lima. A maxwellian path to the q-nonextensive velocity distribution function. *Physics Letters A*, 286(5-6):318–326, 2001. doi: 10.1016/S0375-9601(01)00665-X.

[41] B. M. Boghosian. Thermostatistical description of the relaxation of two-dimensional turbulence using tsallis statistics. *Physical Review E*, 53(5):4754–4763, 1996. doi: 10.1103/PhysRevE.53.4754.

[42] Lisa Borland. Microscopic dynamics of the nonlinear fokker-planck equation: A phenomenological model. *Physical Review E*, 57(6):6634–6642, 1998. doi: 10.1103/PhysRevE.57.6634.

[43] Robert L. Axtell, Joshua M. Epstein, and H. Peyton Young. The emergence of classes in a multi-agent bargaining model. *Center on Social and Economic Dynamics Working Paper*, (9), February 2000. Also discussed in Axtell 2000, JASSS methodology papers.

[44] J.-L. Deneubourg, S. Aron, S. Goss, and J. M. Pasteels. The self-organizing exploratory pattern of the argentine ant. *Journal of Insect Behavior*, 3 (2):159–168, 1990. ISSN 1572-8889. doi: 10.1007/BF01417909. URL `https://doi.org/10.1007/BF01417909`.

[45] Robert J. Shiller and John Pound. Survey evidence on diffusion of investment among institutional investors. Technical Report Working Paper No. 1851, National Bureau of Economic Research, March 1986. URL `https://ssrn.com/abstract=341816`. Available at SSRN: https://ssrn.com/abstract=341816.

[46] David S. Scharfstein and Jeremy C. Stein. Herd behavior and investment. *American Economic Review*, 80(3):465–479, 1990.

[47] N. G. van Kampen. *Stochastic Processes in Physics and Chemistry*. North-Holland, Amsterdam, 2 edition, 1992. ISBN 9780080571386.

[48] R. Rak, S. Drożdż, J. Kwapień, and P. Oświęcimka. Stock returns versus trading volume: Is the correspondence more general? *Acta Physica Polonica B*, 44(10):2035–2050, 2013. ISSN 0587-4254.

[49] S. Gradshteyn, I. and M. Ryzhik, I.˙ *Table of Integrals, Series, and Products*. Elsevier / Academic Press, Amsterdam, seventh edition, 2007. ISBN 978-0-12-373637-6. Translated from the Russian; translation edited and with a preface by Alan Jeffrey and Daniel Zwillinger; incluye CD-ROM.

[50] Crispin W. Gardiner. *Handbook of Stochastic Methods for Physics, Chemistry and the Natural Sciences*. Springer Series in Synergetics. Springer-Verlag, Berlin, 2 edition, 1985. ISBN 9783540156079. 2nded., reimpresa en los 1990s.